



Formação Inteligência Artificial




Introdução à Inteligência Artificial



Representação do Conhecimento

Data Science Academy raphaelbsfontenelle@gmail.com 615c1fdde32fc361b30c9ec2






A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence

August 31, 1955

*John McCarthy, Marvin L. Minsky,
Nathaniel Rochester,
and Claude E. Shannon*






Como fazer as máquinas
compreenderem as coisas?



Introdução



Data Science
Academy

Data Science Academy raphaelbsfontenelle@gmail.com 615c1fdde32fc361b30c9ec2




Data Science Academy



Data Science Academy

Introdução



Data Science
Academy


Data Science Academy raphaelbsfontenelle@gmail.com 615c1fdde32fc361b30c9ec2



Data Science Academy




Data Science Academy



Questões Principais de um Sistema de IA:

Aquisição, Representação e Manipulação de Conhecimento





O que estudaremos neste capítulo?

- Definição de representação do conhecimento
- Engenharia Ontológica
- Categorias, objetos e eventos
- Sistemas de Raciocínio
- Quantificação da Incerteza
- A Regra de Bayes
- Semântica e Inferência Bayesianas
- Raciocínio Probabilístico
- Atividades Práticas em Python para Construção de Agentes Lógicos



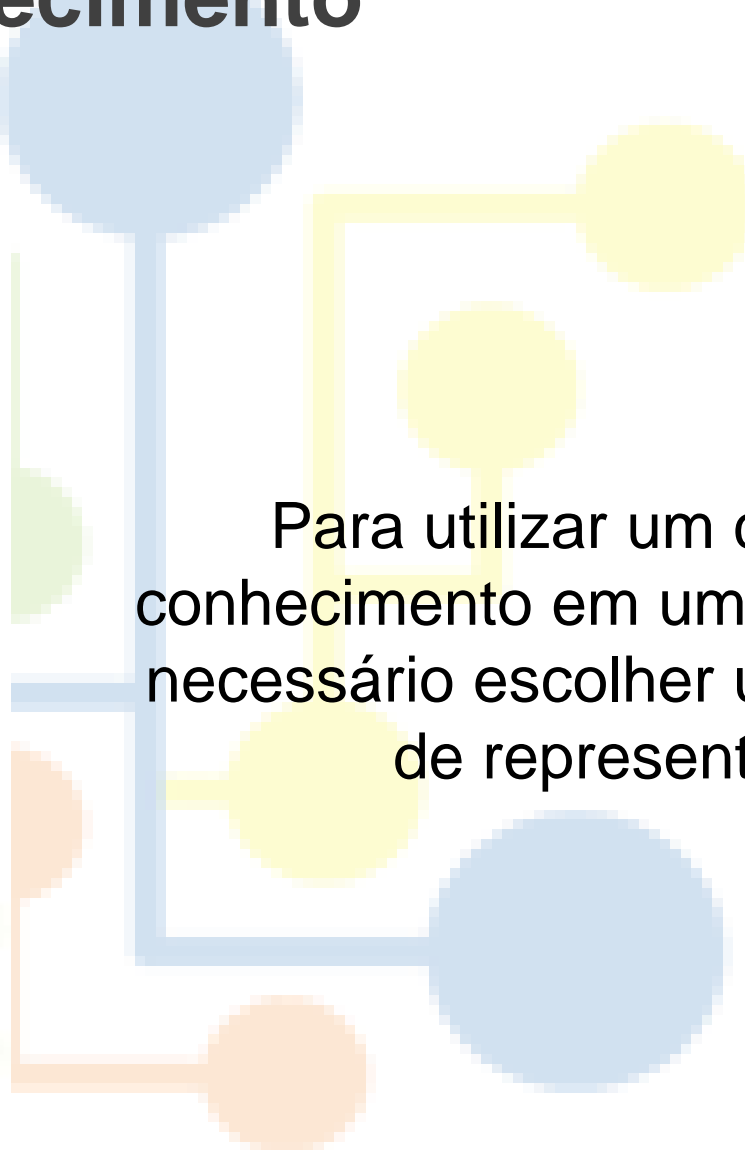
O que é Representação do Conhecimento?



Representação do Conhecimento



Para utilizar um corpo de conhecimento em uma máquina, é necessário escolher uma maneira de representá-lo





Representação do Conhecimento






Representação do Conhecimento





Representação do Conhecimento

Como transmitir o conhecimento do mundo para um robô ou outro sistema computacional, dando-lhe uma capacidade adequada de raciocínio, de modo que este conhecimento possa ser utilizado para permitir ao sistema uma adaptação e exploração do seu ambiente?





Representação do Conhecimento

- De que forma o conhecimento pode ser expresso ?
- Como encontrar a linguagem adequada para a representação deste conhecimento ?
- Como formar uma base de conhecimento suficientemente detalhada e que represente a compreensão do domínio ?
- Como realizar inferências automáticas, dando acesso tanto ao conhecimento implícito na base de conhecimento quanto aquele armazenado explicitamente (declarativo)?
- Como o sistema deve proceder na presença de informações incompletas, incorretas ou de senso comum ?





Representação do Conhecimento

The diagram consists of two rounded rectangular boxes. The top box is light green and contains the text 'Representação do Conhecimento'. A large, solid blue arrow points downwards from this box to a second, darker green rounded rectangular box below it, which contains the text 'Representação do Conhecimento e Raciocínio'. The background of the slide features a faint, abstract network of colored circles (blue, green, yellow, orange) connected by thin lines.

Representação do Conhecimento

Representação do Conhecimento e Raciocínio

Engenharia Ontológica



Engenharia Ontológica

A representação de conceitos abstratos é chamada de
Engenharia Ontológica.



Engenharia Ontológica

Ontologia:

Descrição de conceitos e relacionamentos que devem ser considerados por um agente ou por uma comunidade de agentes.






Engenharia Ontológica

Ontologia:

- **Indivíduos:** os objetos básicos
- **Classes:** conjuntos, coleções ou tipos de objetos
- **Atributos:** propriedades, características ou parâmetros que os objetos podem ter e compartilhar
- **Relacionamentos:** as formas como os objetos podem se relacionar com outros objetos






Engenharia Ontológica

Ontologia:

- **Indivíduos (exemplares)**
- **Classes (conceitos)**
- **Atributos**
- **Relacionamentos**






Ontologia e Ciência da Computação

Existem na literatura várias definições para o termo ontologia em Ciência da Computação.






Ontologia e Ciência da Computação

Ontologia é definida como uma especificação formal e explícita de uma conceitualização compartilhada, onde:

especificação formal quer dizer algo que é legível para os computadores






Ontologia e Ciência da Computação

Ontologia é definida como uma especificação formal e explícita de uma conceitualização compartilhada, onde:

explícita são os conceitos, propriedades, relações, funções, restrições e axiomas explicitamente definidos






Ontologia e Ciência da Computação

Ontologia é definida como uma especificação formal e explícita de uma conceitualização compartilhada, onde:

conceitualização representa um modelo abstrato de algum fenômeno do mundo real e compartilhada significa conhecimento consensual.





Data Science
Academy

Data Science Academy raphaelbsfontenelle@gmail.com 615c1fdde32fc361b30c9ec2

Ontologia e Ciência da Computação

Apesar de apresentarem diferentes definições, o principal propósito da construção de ontologias é permitir compartilhamento e reutilização de conhecimento.



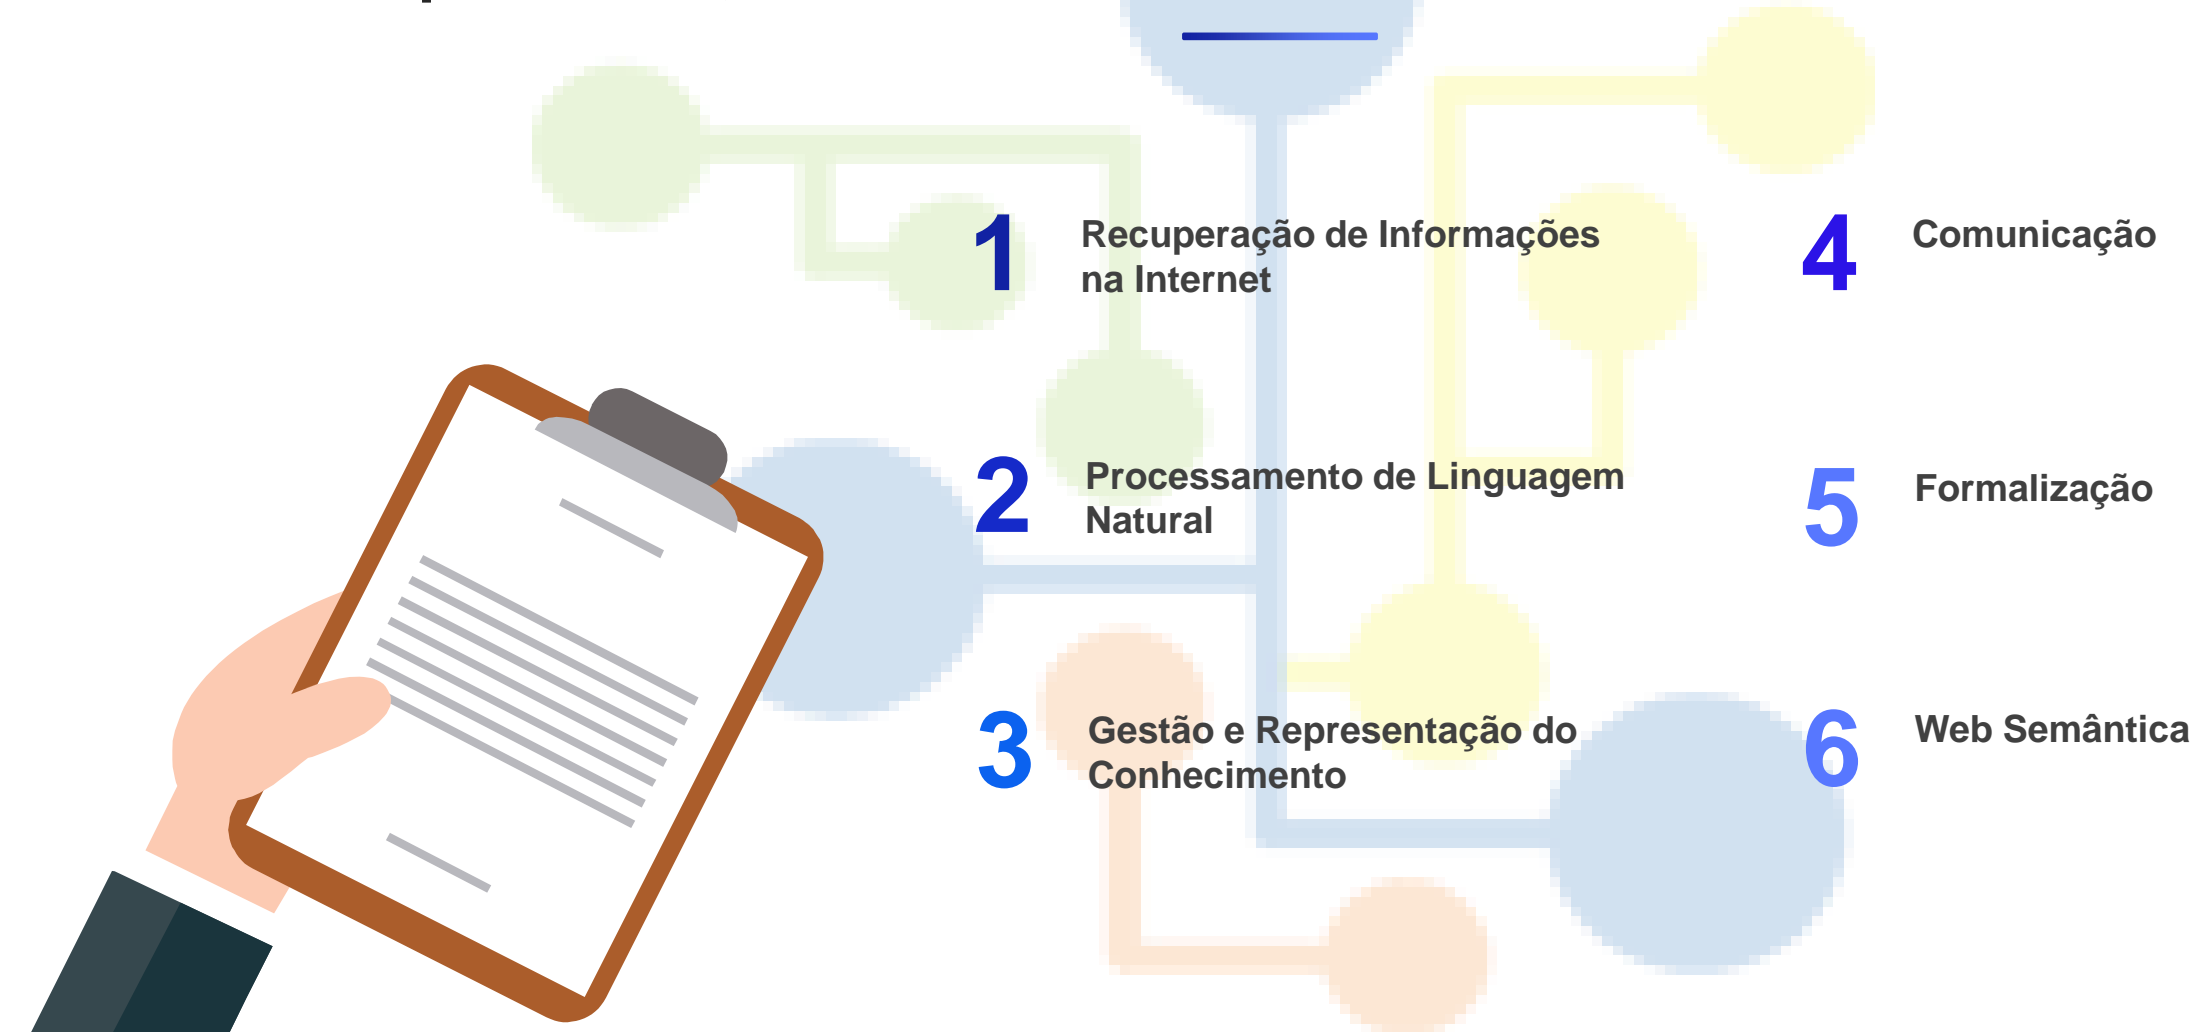
Data Science Academy



Data Science Academy



Principais Usos, Benefícios e Problemas relacionados às Ontologias





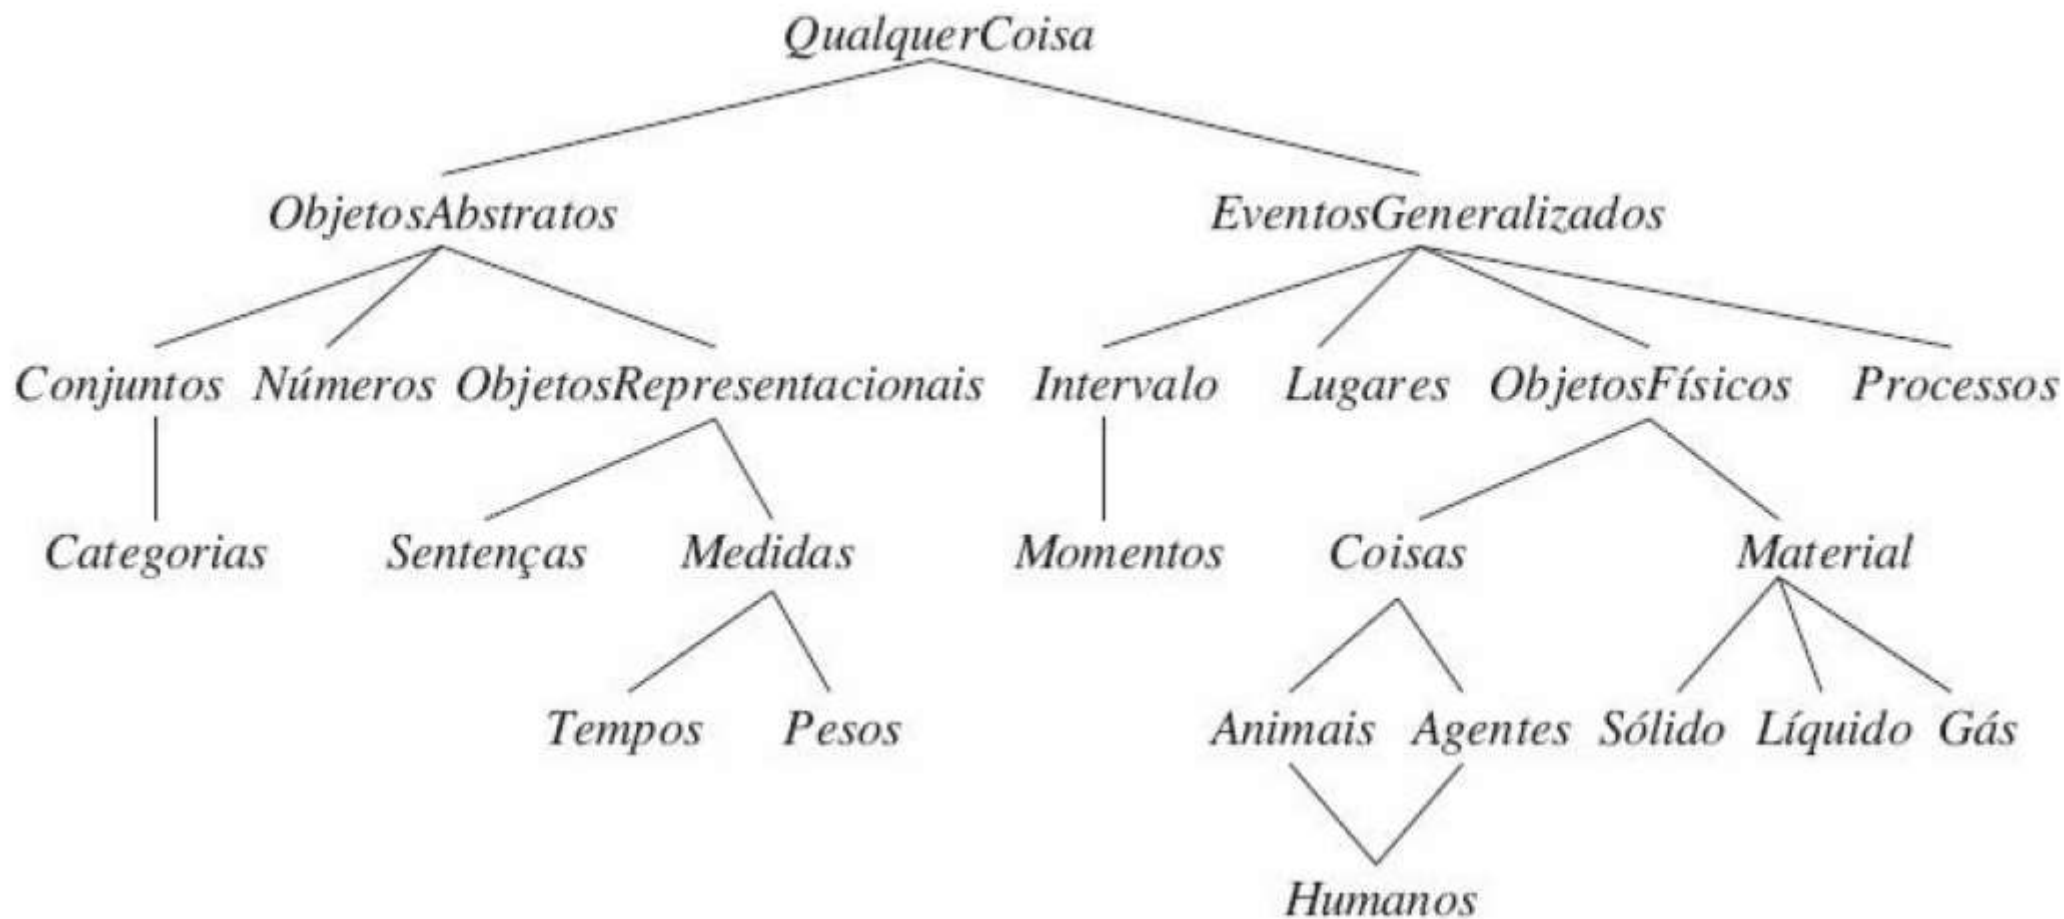
Principais Usos, Benefícios e Problemas relacionados às Ontologias

- Escolha das Ontologias
- Criação e Evolução das Ontologias
- Bibliotecas de Ontologias
- Metodologia de Desenvolvimento






Engenharia Ontológica



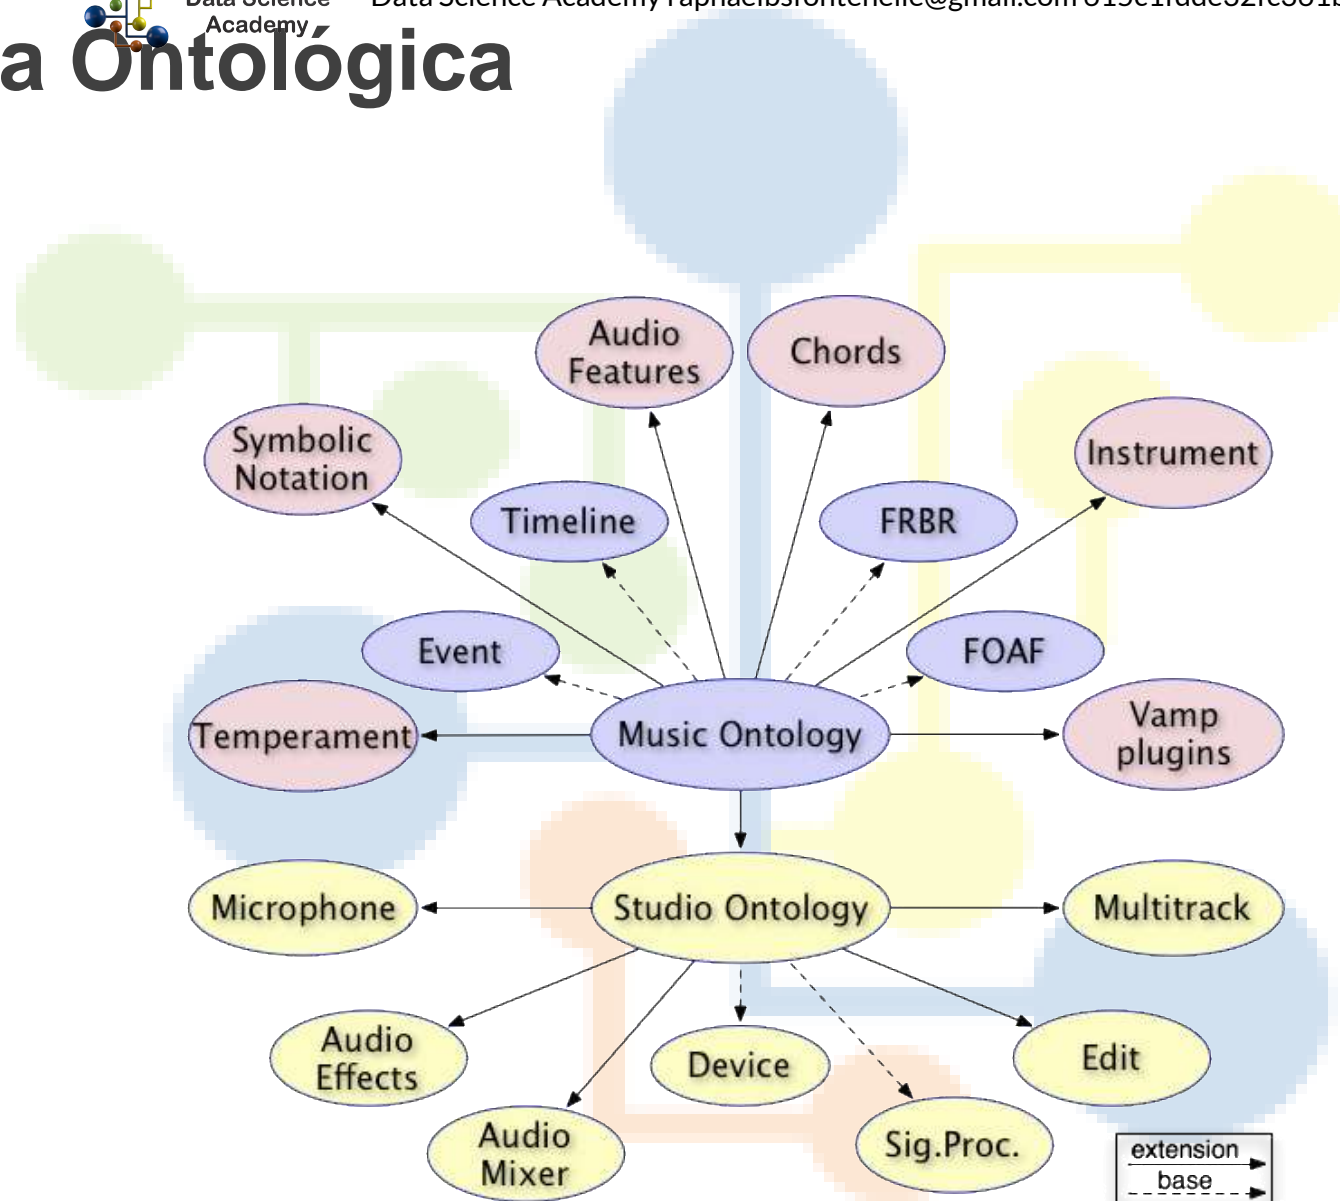


Engenharia Ontológica





Engenharia Ontológica






Engenharia Ontológica


Uma ontologia de uso geral deve ser aplicável em quase todo domínio de uso específico (com a inclusão de axiomas específicos do domínio).

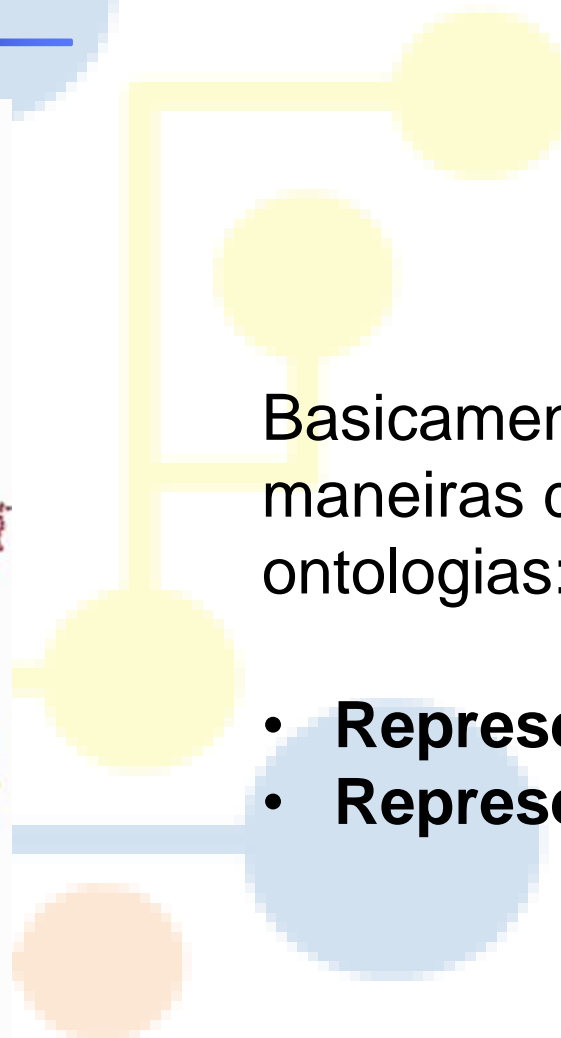




Tipos de Ontologias

- 1 Ontologias Genéricas
- 2 Ontologias de Domínio
- 3 Ontologias de Tarefas
- 4 Ontologia de Aplicação






Basicamente existem duas maneiras de representar ontologias:

- Representação formal
- Representação gráfica




Representação de Ontologias



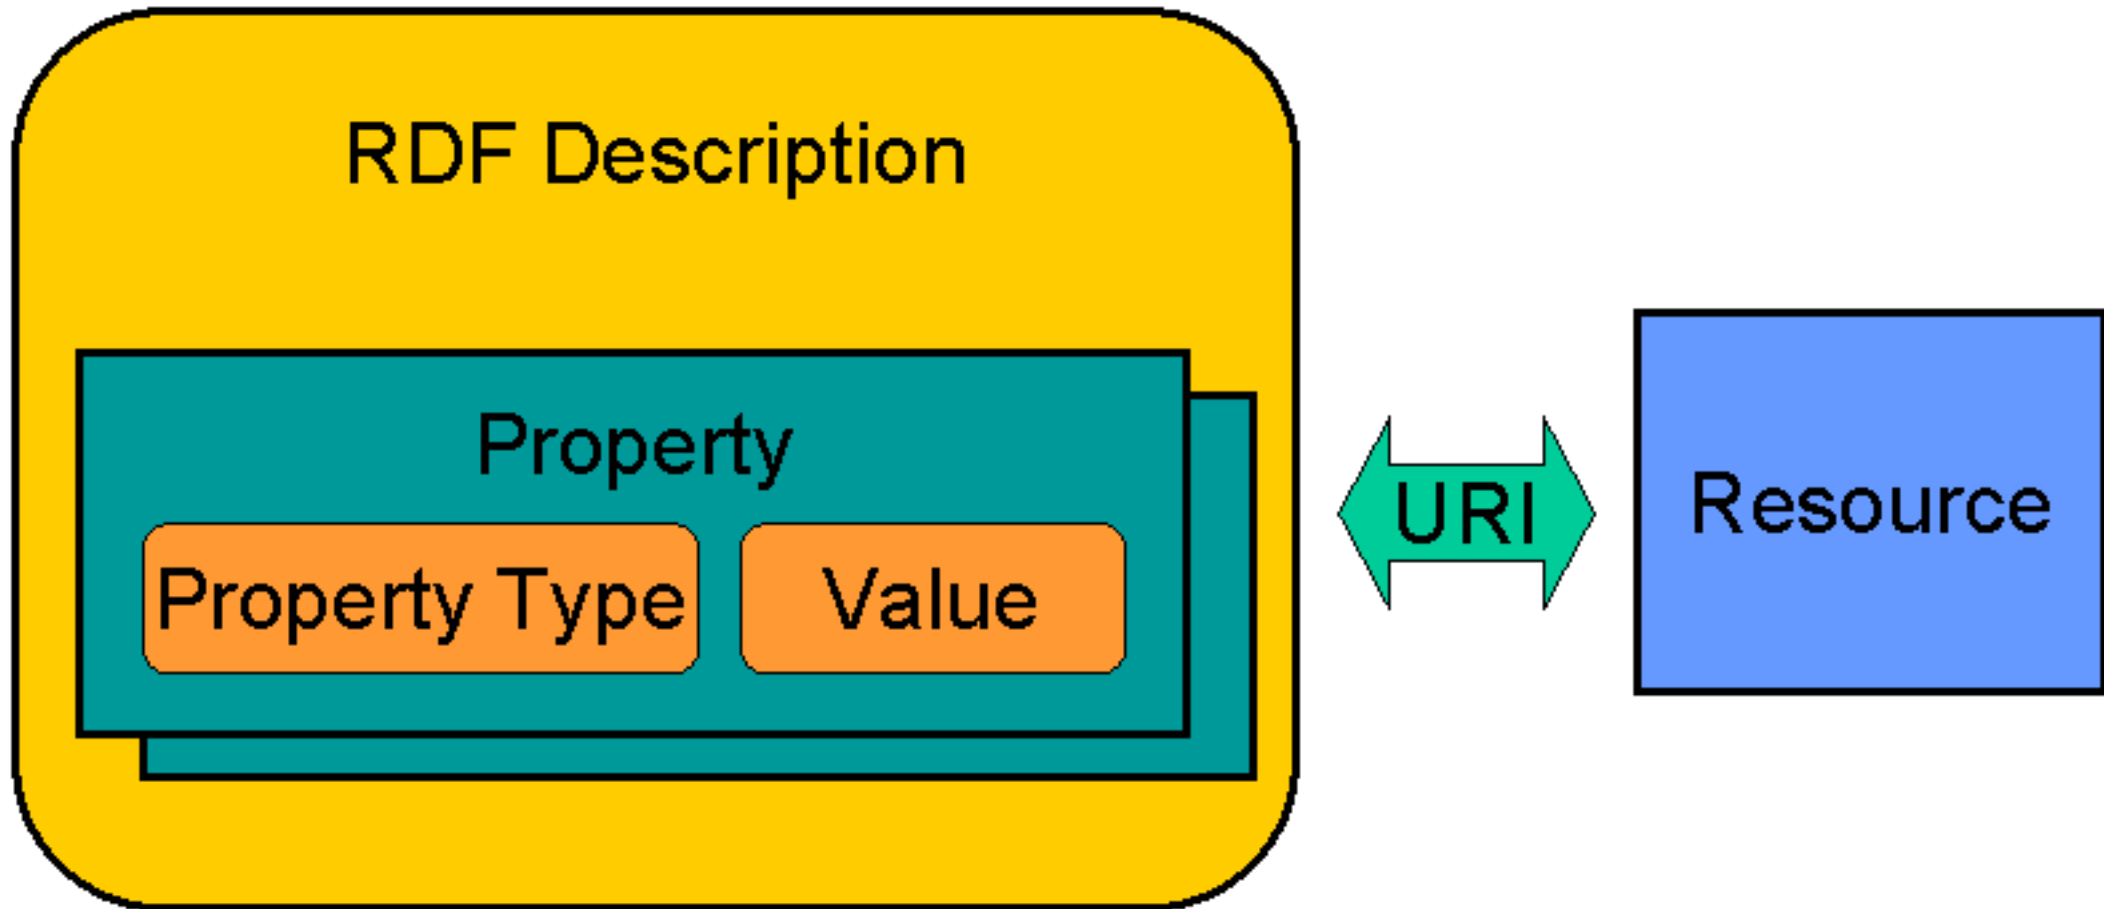
Basicamente existem duas maneiras de representar ontologias:

- Representação formal
 - **RDF**
 - **OWL**





Representação de Ontologias





Representação de Ontologias

```
<owl:Class rdf:ID="Vehicle">
  <rdfs:label>Vehicle</rdfs:label>
  <rdfs:SubClassOf rdf:resource="#Any" />
</owl:Class>
<owl:Class rdf:ID="sport_cycle">
  <rdfs:label>sport_cycle</rdfs:label>
  <rdfs:SubClassOf rdf:resource="#bicycle" />
</owl:Class>
<owl:Class rdf:ID="city_cycle">
  <rdfs:label>city_cycle</rdfs:label>
  <rdfs:SubClassOf rdf:resource="#bicycle" />
</owl:Class>
<owl:Class rdf:ID="bicycle">
  <rdfs:label>bicycle</rdfs:label>
  <rdfs:SubClassOf rdf:resource="#Vehicle" />
  <rdfs:SubClassOf>
    <owl:Restriction>
      <owl:cardinality rdf:datatype="http://www.w3.org/">
        <owl:onProperty rdf:resource="#has_body_color" />
      </owl:Restriction>
    </rdfs:SubClassOf>
  <rdfs:SubClassOf>
    <owl:Restriction>
      <owl:onProperty rdf:resource="#has_body_color" />
      <owl:allValuesFrom rdf:resource="#Color" />
    </owl:Restriction>
  </rdfs:SubClassOf>
</owl:Class>
```

Web Ontology Language (OWL)

Figura 3.2 Representação da ontologia de bicicleta em OWL.
Fonte: <http://www.hozo.jp/>

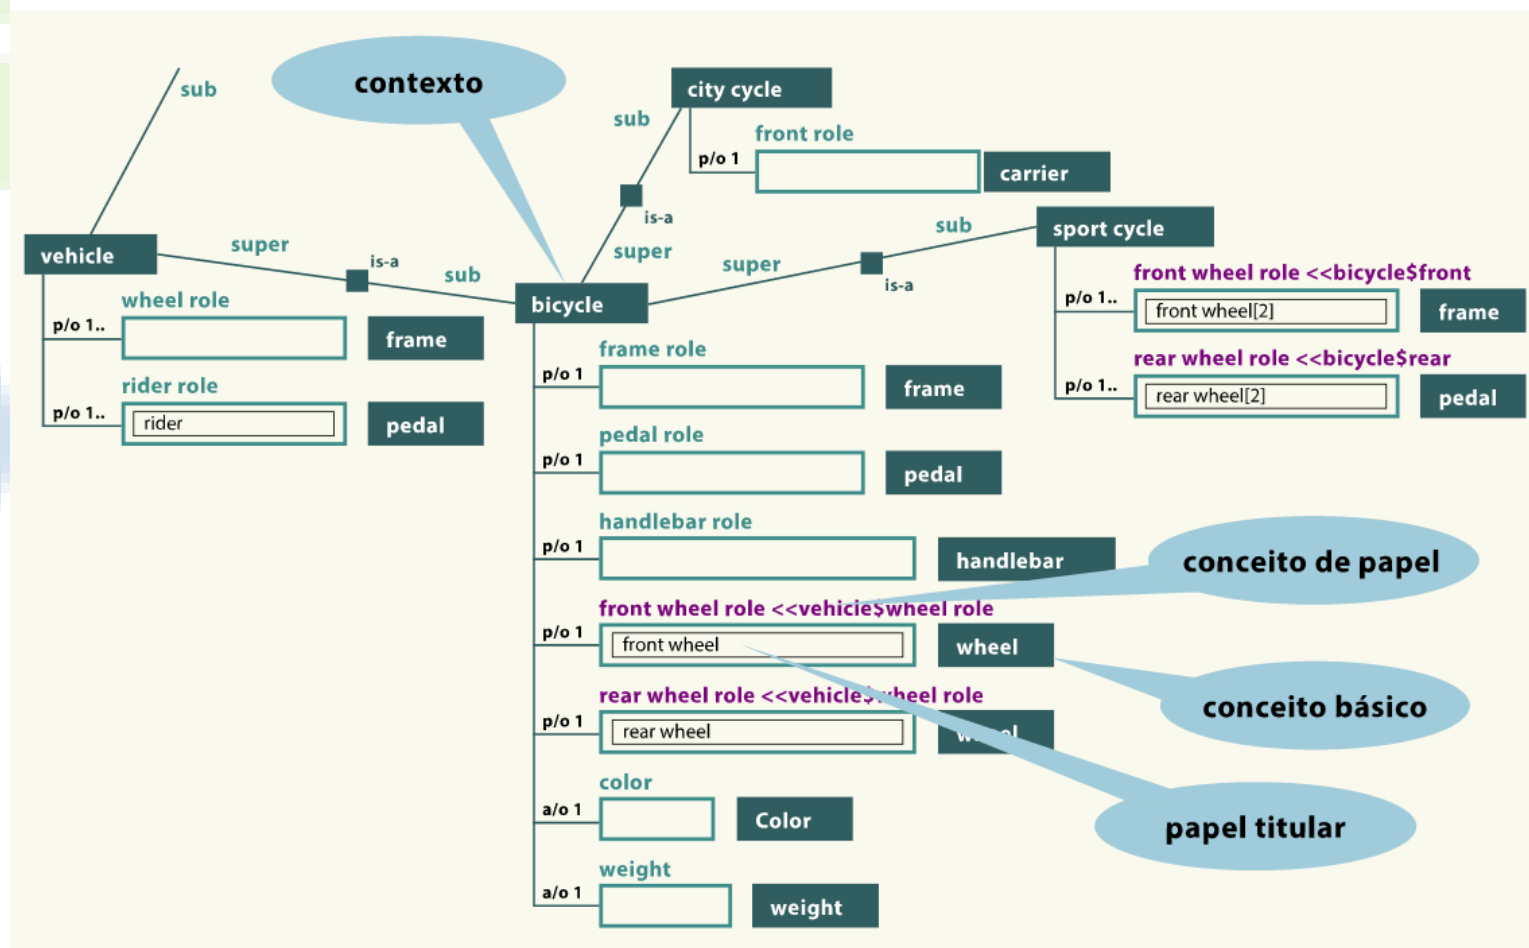




Representação de Ontologias

Existem muitas maneiras de representar graficamente uma ontologia, uma vez que esta é composta principalmente por conceitos e suas relações.

Algumas formas comuns para representar graficamente ontologias são grafos, UML e estrutura de árvore.

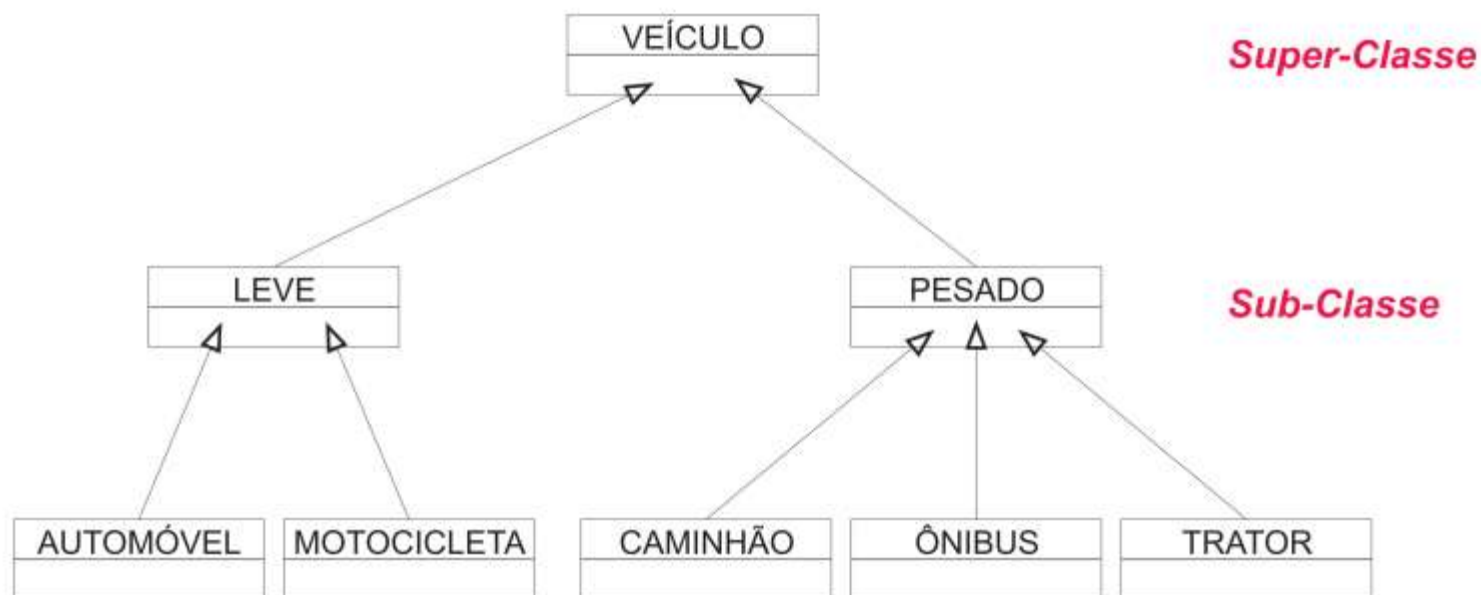




Construção de Ontologias

A construção de ontologias de domínio envolve, primeiramente, a definição de seu domínio e escopo.


- Relações
- Axiomas
- Instâncias
- Funções





Construção de Ontologias


Percebeu a semelhança com linguagem de programação orientada a objetos?






Construção de Ontologias

Lembra como construímos os agentes em Python ao fim do capítulo anterior usando orientação a objetos?



Categorias e Objetos



Categorias e Objetos



Representação de
Conhecimento



Categorias e Objetos

Predicados


Objetos

$\text{Elemento}(b, \text{BolasDeBasquete})$ para dizer que b é um elemento da **categoria** de bolas de basquete

$\text{Subconjunto}(\text{BolasDeBasquete}, \text{Bolas})$, para dizer que BolasDeBasquete é uma **subcategoria** de Bolas

* Transformar uma proposição em um objeto é chamado de **reificação**, da palavra latina *res*, ou “coisa”.
John McCarthy propôs o termo “coisificação”, mas o termo nunca vingou.






Categorias e Objetos

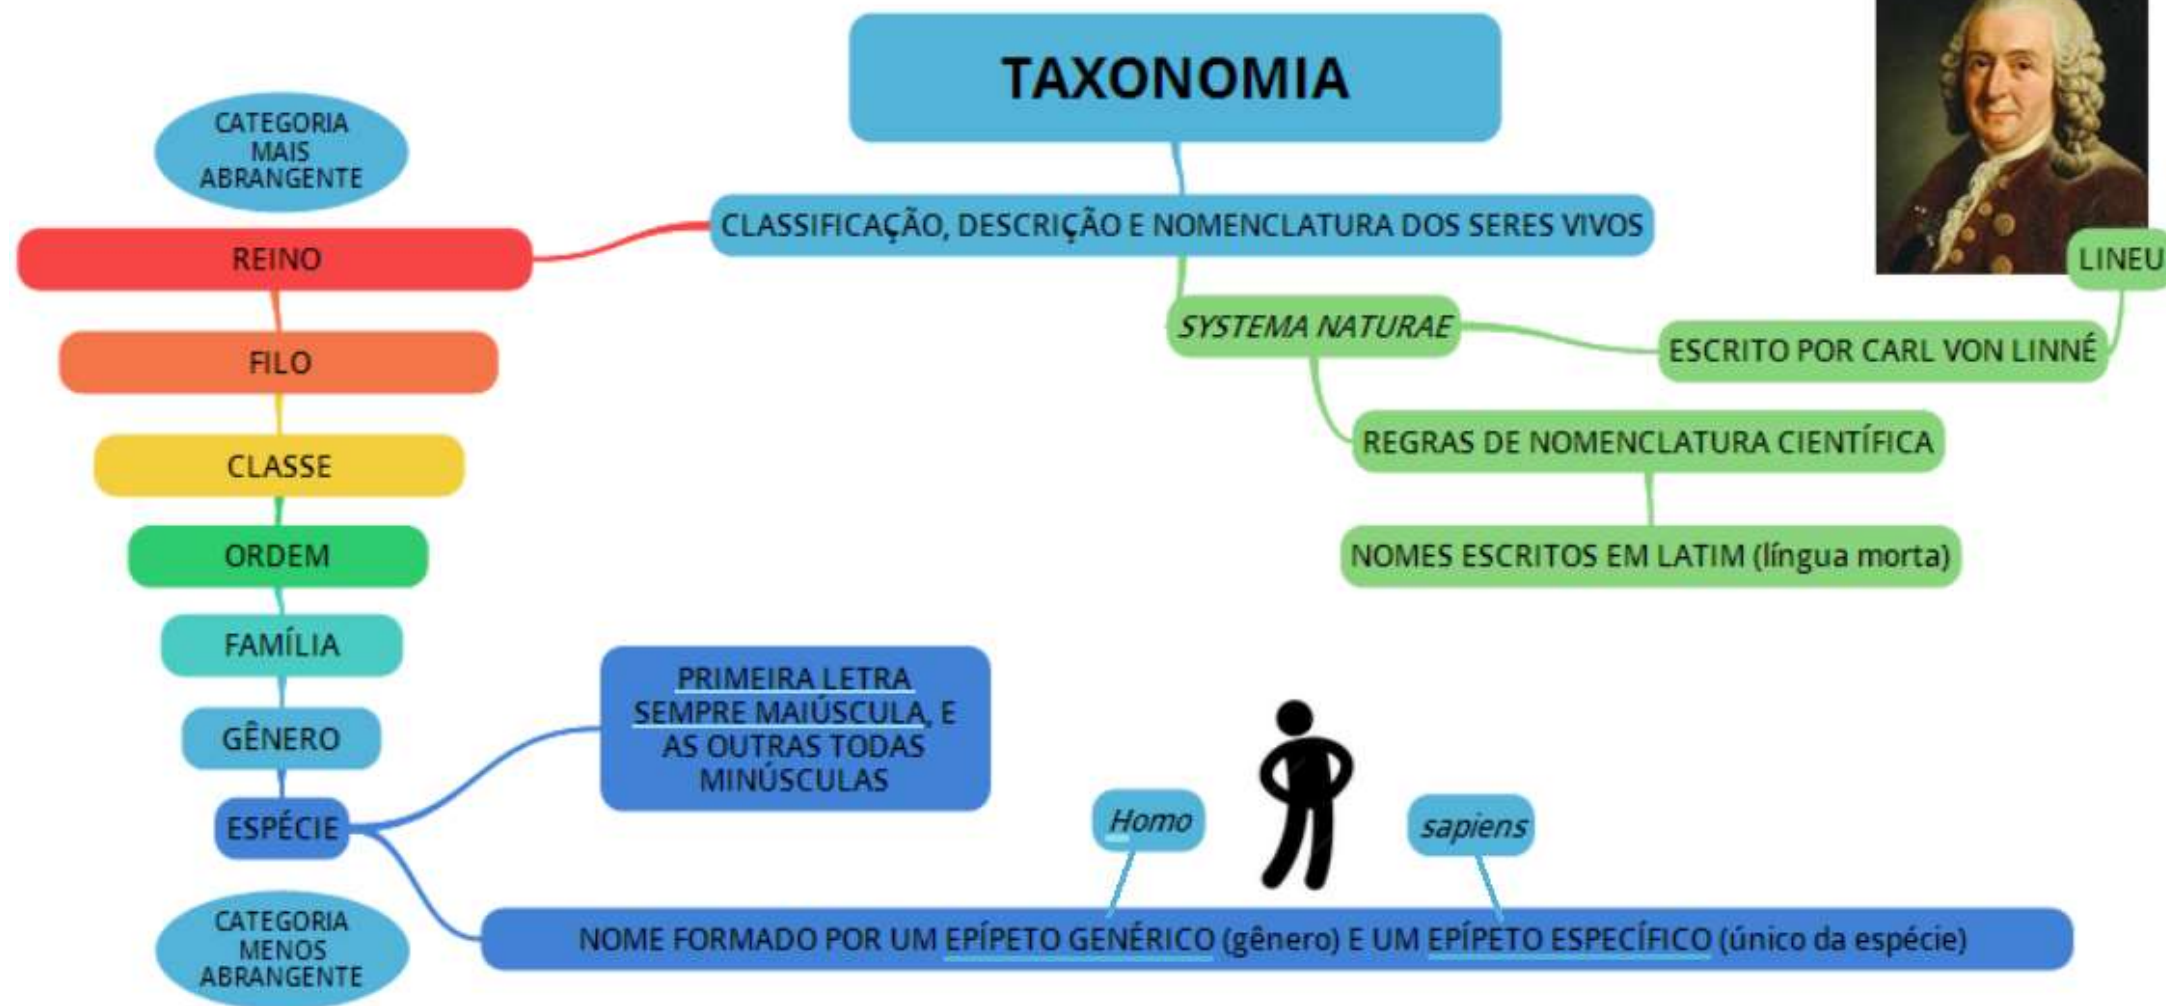



Herança

Se dissermos que todas as instâncias da categoria *Alimento* são comestíveis e se afirmarmos que *Fruta* é uma subclasse de *Alimento* e que *Maçãs* é uma subclasse de *Fruta*, então saberemos que toda maçã é comestível.



Categorias e Objetos






Categorias e Objetos

- Um objeto é um elemento de uma categoria.
- Uma categoria é uma subclasse de outra categoria.
- Todos os elementos de uma categoria têm algumas propriedades.
- Os elementos de uma categoria podem ser reconhecidos por algumas propriedades.
- Uma categoria é um conjunto que tem algumas propriedades.






Categorias e Objetos



Disjuntos($\{\text{Animais}, \text{Vegetais}\}$)


Decomposição Exaustiva($\{\text{Americanos}, \text{Canadenses}, \text{Mexicanos}\}, \text{NorteAmericanos}$)


Partição($\{\text{Machos}, \text{Fêmeas}\}, \text{Animais}$)



Categorias e Objetos

GrupoDe({Maçã1, Maçã2, Maçã3})






Categorias e Objetos

Algumas categorias têm definições estritas: um objeto é um triângulo se e somente se é um polígono com três lados.

Por outro lado, a maioria das categorias no mundo real não tem nenhuma definição clara; essas são as chamadas categorias de **espécies naturais**.



Sistemas de Raciocínio



Sistemas de Raciocínio

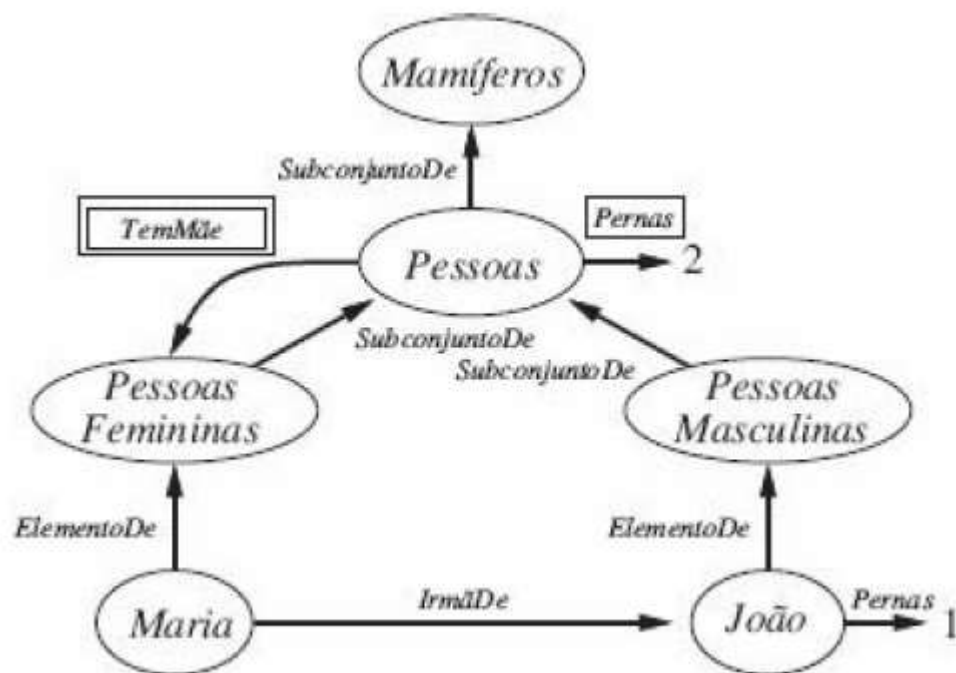

Redes Semânticas

Oferecem auxílios gráficos para visualização de uma base de conhecimento e algoritmos eficientes para dedução de propriedades de um objeto, de acordo com sua pertinência a uma categoria.

Lógicas de Descrição

Fornecem uma linguagem formal para construção e combinação de definições de categorias e algoritmos eficientes para definir relacionamentos de subconjuntos e superconjuntos entre categorias.

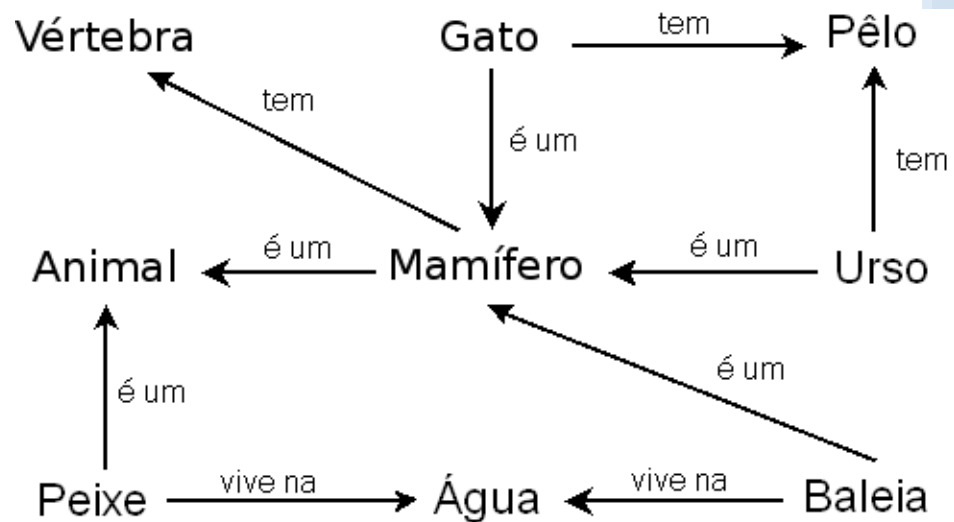




As redes semânticas — *pelo menos aquelas que têm semânticas bem definidas* — são uma forma de lógica.

Redes Semânticas

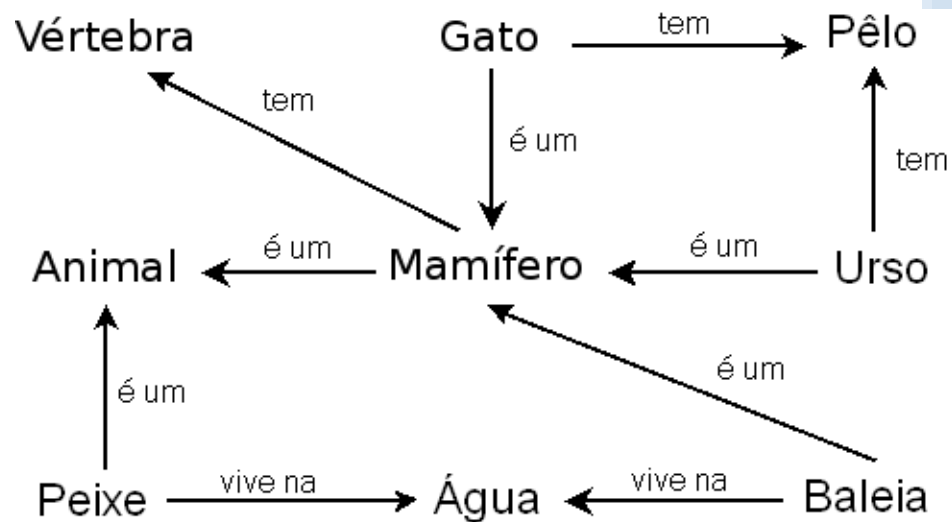




Existem muitas variantes de redes semânticas, mas todas são capazes de representar objetos individuais, categorias de objetos e relações entre objetos.

Redes Semânticas






O conceito foi criado para uso em computadores por Richard H. Richens em 1956 como uma língua internacional auxiliar para a tradução por máquina de linguagens naturais. Foram então desenvolvidas por Robert F. Simmons no início da década de 1960 e posteriormente amplidas através do trabalho de M. Ross Quillian em 1966.

Redes Semânticas






Mecanismo de raciocínio de
redes semânticas

Redes Semânticas






Algoritmo: Herança de Atributos



- Para recuperar um valor V de um atributo A de uma instância O de um objeto:
 - Encontre O na base de conhecimento.
 - Se houver aí um valor para o atributo A , retorne esse valor.
 - Senão, verificar **se há um valor** para a relação *instância*.
Em caso negativo, retorne *insucesso*.
 - Caso contrário**, ir para o nó que corresponde àquele valor e **procurar um valor** para o atributo A .
Se encontrar, retorne o valor.
 - Caso contrário**, execute os passos a seguir até não haver mais valor para a relação *é-um* ou até encontrar uma resposta:
 - Encontrar o valor da relação *é-um* e ir para aquele nó.
 - Verificar se há um valor para o atributo A . Se houver, retorne-o.

Redes Semânticas

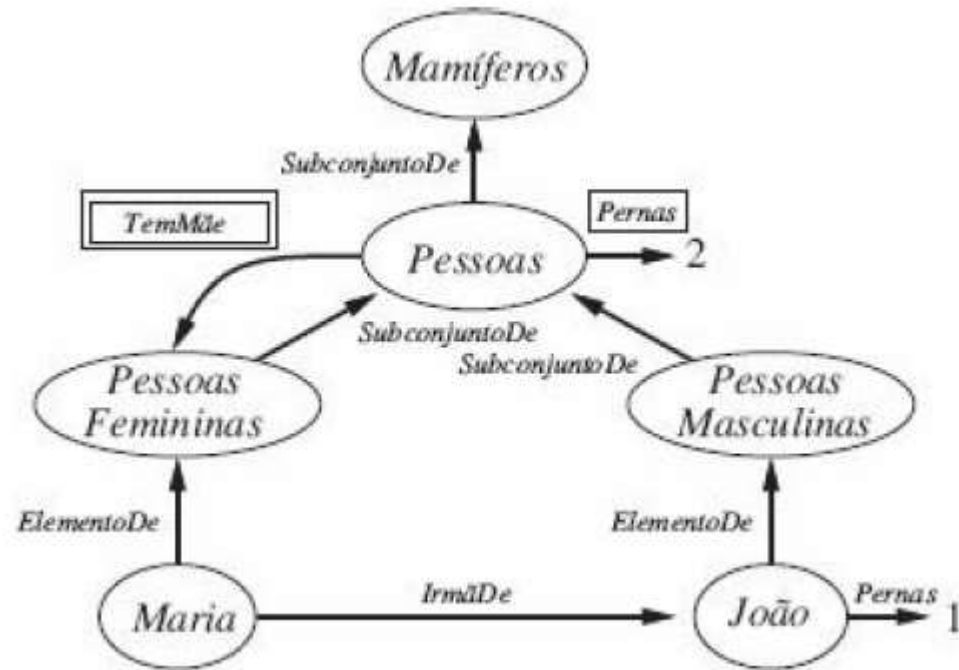




A herança fica complicada quando um objeto pode pertencer a mais de uma categoria ou quando uma categoria pode ser um subconjunto de mais de uma outra categoria - isso se chama **herança múltipla**.

Redes Semânticas






A semântica default é naturalmente imposta pelo algoritmo de herança porque segue arcos ascendentes desde o próprio objeto (João, nesse caso) e para tão logo encontra um valor.

Redes Semânticas





As **lógicas de descrição** são notações projetadas para tornar mais fácil descrever definições e propriedades de categorias.

Conceito → **Thing** | *NomeConceito*

| **And**(*Conceito*,...)

| **All**(*NomePapel*, *Conceito*)

| **AtLeast**(*Inteiro*, *NomePapel*)

| **AtMost**(*Inteiro*, *NomePapel*)

| **Fills**(*NomePapel*, *NomeIndivíduo*,...)


| **SameAs**(*Caminho*, *Caminho*)

| **OneOf**(*NomeIndivíduo*,...)

Caminho → [*NomePapel*,...]

Lógicas de Descrição





As principais tarefas de inferência para lógicas de descrição são a **subordinação** (verificar se uma categoria é um subconjunto de outra pela comparação de suas definições) e a **classificação** (verificar se um objeto pertence a uma categoria).

Conceito → **Thing** | *NomeConceito*

| **And**(*Conceito*,...)

| **All**(*NomePapel*, *Conceito*)

| **AtLeast**(*Inteiro*, *NomePapel*)

| **AtMost**(*Inteiro*, *NomePapel*)

| **Fills**(*NomePapel*, *NomeIndivíduo*,...)


| **SameAs**(*Caminho*, *Caminho*)

| **OneOf**(*NomeIndivíduo*,...)

Caminho → [*NomePapel*,...]

Lógicas de Descrição





Linguagem Classic

Solteiro = And(NãoCasado, Adulto, Homem)

Conceito → **Thing** | *NomeConceito*

| **And**(*Conceito*,...)

| **All**(*NomePapel*, *Conceito*)

| **AtLeast**(*Inteiro*, *NomePapel*)

| **AtMost**(*Inteiro*, *NomePapel*)

| **Fills**(*NomePapel*, *NomeIndivíduo*,...)


| **SameAs**(*Caminho*, *Caminho*)

| **OneOf**(*NomeIndivíduo*,...)

Caminho → [*NomePapel*,...]

Lógicas de Descrição





And(Homem, AtLeast(3, Filho), AtMost(2, Filha),
All(Filho, And(Desempregado, Casado, All(Esposa, Médica))),
All(Filha, And(Professora, Fills(Departamento, Física, Matemática))))

Conceito → **Thing** | *NomeConceito*

| **And**(*Conceito*,...)

| **All**(*NomePapel*, *Conceito*)

| **AtLeast**(*Inteiro*, *NomePapel*)

| **AtMost**(*Inteiro*, *NomePapel*)

| **Fills**(*NomePapel*, *NomeIndivíduo*,...)


| **SameAs**(*Caminho*, *Caminho*)

| **OneOf**(*NomeIndivíduo*,...)

Caminho → [*NomePapel*,...]

Lógicas de Descrição





O aspecto mais importante das lógicas de descrição seja sua ênfase na tratabilidade da inferência.

Conceito → **Thing** | *NomeConceito*

| **And**(*Conceito*,...)

| **All**(*NomePapel*, *Conceito*)

| **AtLeast**(*Inteiro*, *NomePapel*)

| **AtMost**(*Inteiro*, *NomePapel*)

| **Fills**(*NomePapel*, *NomeIndivíduo*,...)

| **SameAs**(*Caminho*, *Caminho*)


| **OneOf**(*NomeIndivíduo*,...)

Caminho → [*NomePapel*,...]

Lógicas de Descrição



Quantificando a Incerteza



Quantificando a Incerteza

Os agentes podem precisar lidar com a incerteza, seja devido a um ambiente parcialmente observável, ao não determinismo ou a uma combinação dos dois.





Quantificando a Incerteza

Um plano de contingência correto que lida com toda eventualidade pode crescer arbitrariamente e deve considerar as contingências arbitrariamente improváveis.

Às vezes, não há um plano garantido de alcançar o objetivo — mesmo assim o agente deve agir. Deve ter alguma maneira de comparar os méritos dos planos que não são garantidos.





Quantificando a Incerteza



Plano: A90



Quantificando a Incerteza



Plano: A90



Plano: A180




Quantificando a Incerteza



Portanto, a alternativa correta — *a decisão racional* — depende tanto da importância relativa de várias metas quanto da probabilidade de que elas serão alcançadas e em que grau.





Quantificando a Incerteza

DorDeDente → Cárie.


DorDeDente → Cárie ∨ Gengivite ∨ Abscessos...

Cárie → DorDeDente.

Tentar usar a lógica de primeira ordem para lidar com um domínio como diagnóstico médico é uma abordagem falha, por três razões principais:

- Preguiça
- Ignorância teórica
- Ignorância prática





Quantificando a Incerteza

DorDeDente \rightarrow Cárie.

DorDeDente \rightarrow Cárie \vee Gengivite \vee Abscessos...

Cárie \rightarrow DorDeDente.

Nossa principal ferramenta para lidar com graus de crença será a **teoria da probabilidade**.

Um agente lógico acredita que cada sentença seja verdadeira ou falsa ou não tem opinião, enquanto um agente probabilístico pode ter um grau de crença numérico entre 0 (para sentenças que são certamente falsas) e 1 (certamente verdadeiras).





Hummm... Está começando a fazer sentido!!!!



Quantificando a Incerteza


*A probabilidade proporciona um meio para **resumir** a incerteza que vem de nossa preguiça e ignorância, resolvendo assim o problema de qualificação.*






Quantificando a Incerteza

Um ponto confuso é que, no momento do nosso diagnóstico, não há incerteza no mundo real: o paciente tem uma cárie ou não. Então, o que significa dizer que a probabilidade de uma cárie é de 0,8? Não deveria ser 0 ou 1?





Quantificando a Incerteza

Incerteza e decisões racionais



Plano: A90
Plano: A180
Plano: A1440





Quantificando a Incerteza



A teoria da utilidade diz que todo estado tem determinado grau de utilidade (ou seja, ele tem certa utilidade) para um agente e que o agente preferirá estados com utilidade mais alta.






Quantificando a Incerteza

Por exemplo, a utilidade de um estado em uma partida de xadrez em que a peça branca colocou a preta em xeque é obviamente alta para o agente que joga com a branca, mas baixa para o agente que joga com a preta.





Quantificando a Incerteza

Teoria da decisão = teoria da probabilidade + teoria da utilidade





Quantificando a Incerteza

função AGENTE-TD(*percepção*) **retorna** uma *ação*

variáveis estáticas: *estado_de_crença*, crenças probabilísticas sobre o estado atual do mundo
ação, a ação do agente

atualizar *estado_de_crença* com base em *ação* e *percepção*

calcular probabilidades de resultados de ações,


dadas descrições de ações e o *estado_de_crença* atual

selecionar *ação* com utilidade esperada mais alta

dadas as probabilidades de resultados e informações de utilidade

retornar *ação*






Quantificando a Incerteza





Quantificando a Incerteza

Na teoria da probabilidade, o conjunto de todos os mundos possíveis é chamado de **espaço amostral**






Quantificando a Incerteza

Por exemplo, se jogamos dois dados (distintos), existem 36 mundos possíveis a considerar: $(1,1), (1,2), \dots, (6,6)$. A letra grega Ω (ômega maiúsculo) é usada para se referir ao espaço amostral, e ω (ômega minúsculo) refere-se aos elementos do espaço, isto é, aos mundos possíveis particulares.






Quantificando a Incerteza

$$0 \leq P(\omega) \leq 1 \text{ para cada } \omega \text{ e } \sum_{\omega \in \Omega} P(\omega) = 1$$

Se assumirmos que os dois dados não são “viciados” e um lançamento não interfere no outro, cada um dos mundos possíveis $(1,1), (1,2), \dots, (6,6)$ tem probabilidade $1/36$.






Quantificando a Incerteza

Em IA, os conjuntos são sempre descritos por **proposições** em uma linguagem formal. Para cada proposição, o conjunto correspondente contém apenas aqueles mundos possíveis onde a proposição é válida. A probabilidade associada a uma proposição é definida como sendo a soma das probabilidades dos mundos nos quais é válida:

$$\text{Para qualquer proposição } \phi, P(\phi) = \sum_{\omega \in \phi} P(\omega)$$






Quantificando a Incerteza

Por exemplo, ao jogar dados que não são viciados, temos:

$$P(\text{Total} = 11) = P((5, 6)) + P((6, 5)) = 1/36 + 1/36 = 1/18$$






Quantificando a Incerteza

Probabilidades, tais como $P(\text{Total} = 11)$ e $P(\text{duplas})$ são chamadas **probabilidades incondicionais** ou **anteriores**.

Da mesma forma, se eu estou indo ao dentista para um *check-up* regular, a probabilidade $P(\text{cárie}) = 0,2$ pode ser interessante, mas se estou indo ao dentista porque tenho uma dor de dente, é $P(\text{cárie} \mid \text{dor de dente}) = 0,6$ que importa.






Quantificando a Incerteza

É importante compreender que $P(\text{cárie}) = 0,2$ ainda é válido após a dor de dente ter sido observada;

Ela simplesmente não é especialmente útil.





Quantificando a Incerteza

Matematicamente falando, as probabilidades condicionais são definidas em termos de probabilidades incondicionais como segue:

para quaisquer proposições a e b , temos:

$$P(a \mid b) = \frac{P(a \wedge b)}{P(b)},$$

que é válido sempre que $P(b) > 0$. Por exemplo,

$$P(\text{dupla} \mid \text{Dado}_1 = 5) = \frac{P(\text{dupla} \wedge \text{Dado}_1 = 5)}{P(\text{Dado}_1 = 5)},$$






Quantificando a Incerteza

$$P(a \mid b) = \frac{P(a \wedge b)}{P(b)}$$




$$P(a \wedge b) = P(a \mid b) P(b)$$



A Regra de Bayes




A Regra de Bayes





A Regra de Bayes

Em teoria da probabilidade o Teorema de Bayes mostra a relação entre uma probabilidade condicional e a sua inversa.





A Regra de Bayes

O primeiro a empregar o método bayesiano em problemas de física foi o matemático francês Pierre de Simon Laplace.





A Regra de Bayes

Graças ao grande aumento na capacidade de processamento dos computadores, a abordagem bayesiana tem renascido com grande força.





A Regra de Bayes

$$\Pr(A|B) = \frac{\Pr(B|A) \Pr(A)}{\Pr(B)}$$


- $\Pr(A)$ e $\Pr(B)$ são as probabilidades a priori de A e B.
- $\Pr(B|A)$ e $\Pr(A|B)$ são as probabilidades a posteriori de B condicional a A e de A condicional a B respectivamente.





A Regra de Bayes

A principal crítica à teoria bayesiana é que ela tem um fator que é *subjetivo*, a escolha do prior (prévio).






A Regra de Bayes

A principal crítica à teoria bayesiana é que ela tem um fator que é *subjetivo*, a escolha do prior.

Dados são inúteis se eles não estiverem contextualizados.






A Regra de Bayes

A regra de Bayes, muito além de um resultado matemático útil, dá origem a toda uma visão de mundo e quantifica o que é *ser racional*.


A expressão matemática do teorema de Bayes liga a inferência racional (probabilidade posterior) com a subjetividade das nossas visões prévias (prior) e as evidências empíricas.





A Regra de Bayes

O teorema de Bayes liga a razão humana ao universo físico.



Raciocínio Probabilístico



Raciocínio Probabilístico





Raciocínio Probabilístico

Representação do Conhecimento em um Domínio Incerto

As redes bayesianas podem representar essencialmente qualquer distribuição de probabilidade conjunta completa.

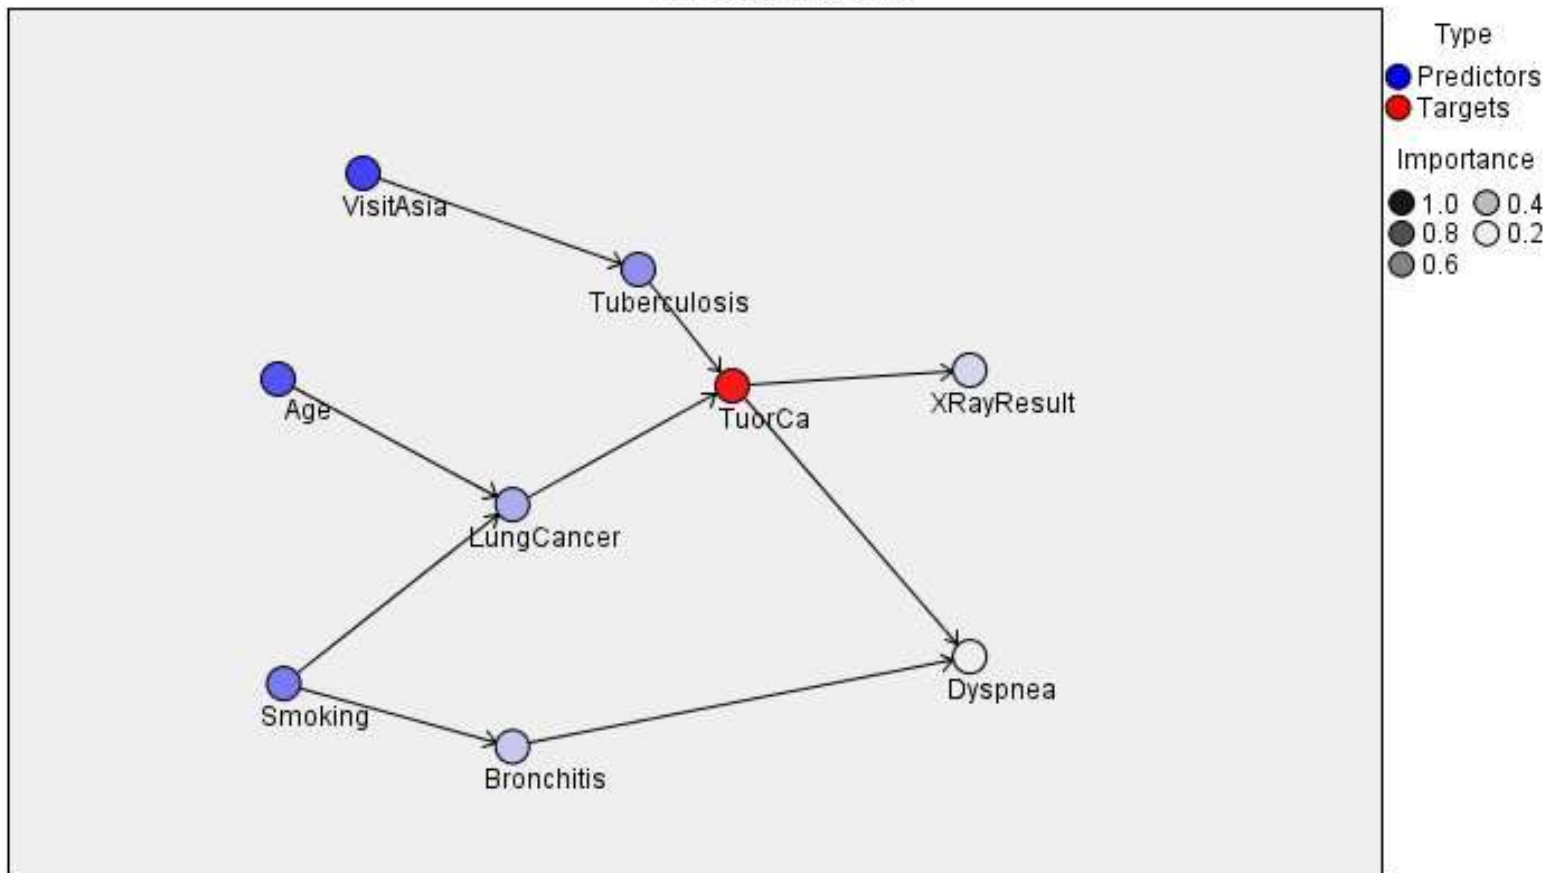




Raciocínio Probabilístico


1. Cada nó corresponde a uma variável aleatória, que pode ser discreta ou contínua.
2. Um conjunto de vínculos orientados ou setas conecta pares de nós. Se houver uma seta do nó X até o nó Y , X será denominado *pai* de Y . O grafo não tem ciclos orientados (e, portanto, é um grafo acíclico orientado, ou GAO).
3. Cada nó X_i tem uma distribuição de probabilidade condicional $P(X_i | Pais(X_i))$ que quantifica o efeito dos pais sobre o nó.

Bayesian Network





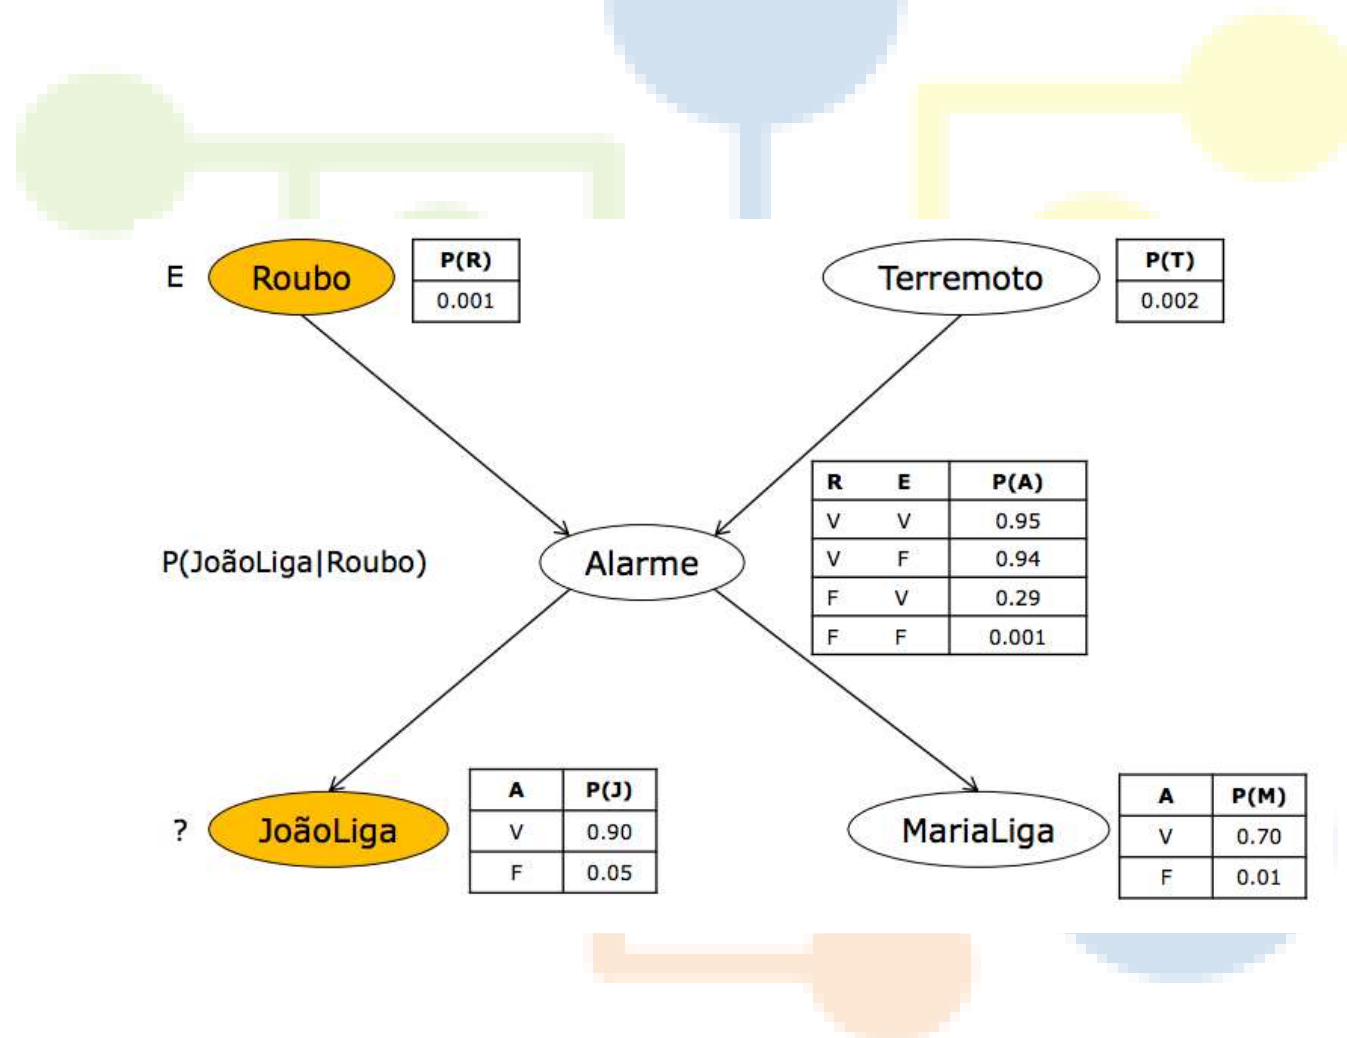
Raciocínio Probabilístico



Formalmente, a independência condicional de *DorDeDente* e *Boticão* dada *Cárie* é a *ausência* de um vínculo entre *DorDeDente* e *Boticão*. Intuitivamente, a rede representa o fato de que *Cárie* é uma causa direta de *DorDeDente* e *Boticão*, enquanto não existe nenhum relacionamento causal direto entre *DorDeDente* e *Boticão*.

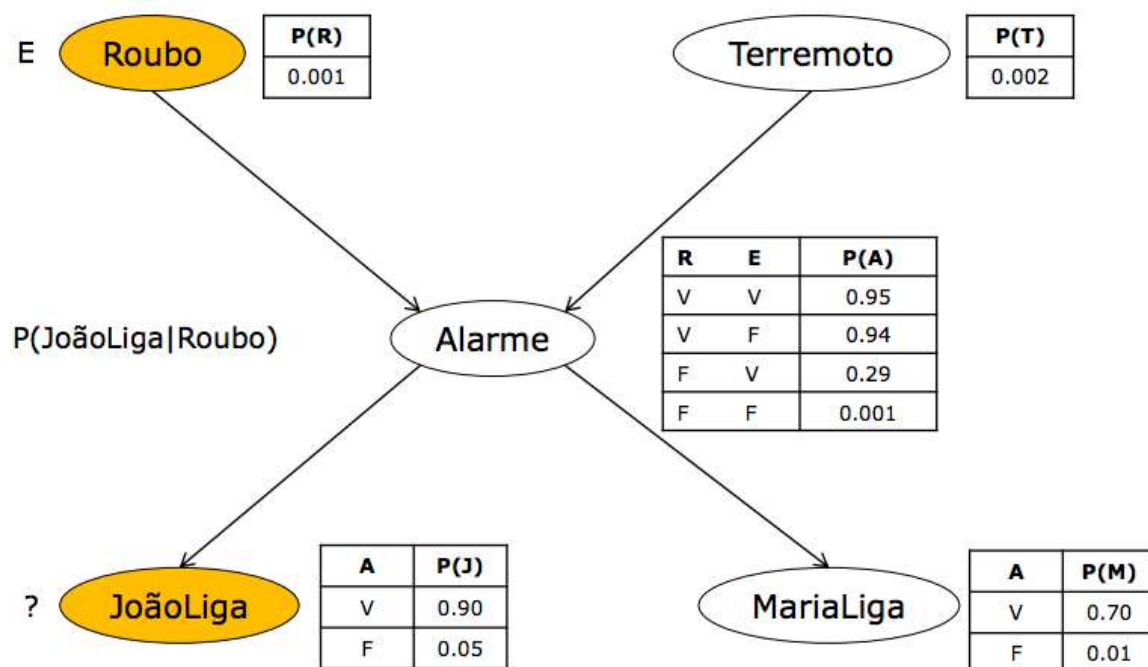


Raciocínio Probabilístico





Raciocínio Probabilístico




Uma rede bayesiana típica, mostrando a topologia e também as tabelas de probabilidade condicional (TPCs).

Nas TPCs, as letras *R*, *T*, *A*, *J* e *M* representam *Roubo*, *Terremoto*, *Alarme*, *JoãoLiga* e *MariaLiga*, respectivamente.







Raciocínio Probabilístico



Note que a rede não tem nós correspondentes ao fato de Maria estar ouvindo música em alto volume no momento ou ao fato de o telefone tocar e confundir João. Esses fatores são resumidos na incerteza associada aos vínculos de *Alarme* para *JoãoLiga* e *MariaLiga*.

Raciocínio Probabilístico Temporal





Raciocínio Probabilístico Temporal

Tempo e Incerteza






Raciocínio Probabilístico Temporal

Tempo e Incerteza

As mesmas considerações surgem em muitos outros contextos, tal como acompanhar a localização do robô, o controle da atividade econômica de uma nação, até dar sentido a uma sequência de palavras faladas. Como é possível modelar situações dinâmicas como essas?





Raciocínio Probabilístico Temporal

Tempo e Incerteza

Vemos o mundo como uma série de instantâneos, ou fatias de tempo, cada uma das quais contém um conjunto de variáveis aleatórias, algumas observáveis, e outras, não!

X_t para indicar o conjunto de variáveis de estados no tempo t

E_t para indicar o conjunto de variáveis de evidência observáveis





Raciocínio Probabilístico Temporal


Tempo e Incerteza

- **Variáveis de evidência:**
 - AçúcarNoSangueMedidot
 - Pulsaçãot
- **Variáveis de estado:**
 - AçúcarNoSanguet
 - ConteúdoDoEstômagot

X_t para indicar o conjunto de variáveis de estados no tempo t

E_t para indicar o conjunto de variáveis de evidência observáveis






Raciocínio Probabilístico Temporal

Modelos de transição e de sensores

$$P(X_t | X_{0:t-1})$$

$$P(X_t | X_{0:t-1}) = P(X_t | X_{t-1})$$






Raciocínio Probabilístico Temporal

Modelos de transição e de sensores

$$P(X_t | X_{0:t-1}) = P(X_t | X_{t-1})$$



Modelo de transição para um processo de Markov de segunda ordem.

$$P(X_t | X_{t-2}, X_{t-1})$$





Raciocínio Probabilístico Temporal

Modelos de transição e de sensores

$$P(E_t | X_{0:t}, E_{0:t-1}) = P(E_t | X_t)$$





Raciocínio Probabilístico Temporal

Inferência em Modelos Temporais


- **Filtragem**
- **Previsão**
- **Suavização**
- **Explicação Mais Provável**
- **Aprendizagem**





Raciocínio Probabilístico Temporal

O aprendizado exige a inferência de suavização total, e não a filtragem, porque a suavização fornece melhores estimativas dos estados do processo.



Data Science
Academy

Data Science Academy raphaelbsfontenelle@gmail.com 615c1fdde32fc361b30c9ec2

Obrigado



Data Science Academy



Data Science Academy