



Formação Inteligência Artificial







Programação Paralela em GPU









Computação em GPU

As GPUs são processadores especializados em processar imagem e são extremamente poderosos devido a sua arquitetura paralela e sua eficiência, tanto no acesso a memória como nas operações vetoriais e de interpolação







OpenCL™



PyCUDA

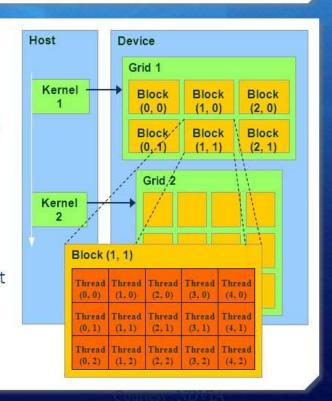
MATLAB[®]



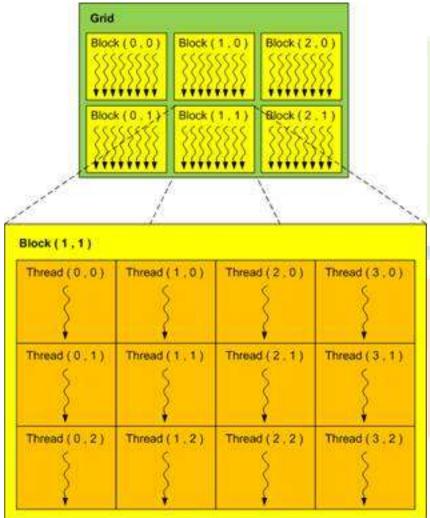
Uma função CUDA é chamada de kernel

Thread Batching: Grids and Blocks

- A kernel is executed as a grid of thread blocks
 - All threads share data memory space
- A thread block is a batch of threads that can cooperate with each other.
- Threads and blocks have IDs
 - So each thread can decide what data to work on
 - Grid Dim: 1D or 2D
 - ▶ Block Dim: 1D, 2D, or 3D



Computação em GPU



As threads são organizadas em grupos que são chamados de blocks, que por sua vez são organizados e chamados de grids.



Computação em GPU

1D Grid of 2D Blocks

Grid

Block 0Threads0,00,10,20,30,41,01,11,21,31,42,02,12,22,32,43,03,13,23,34,4

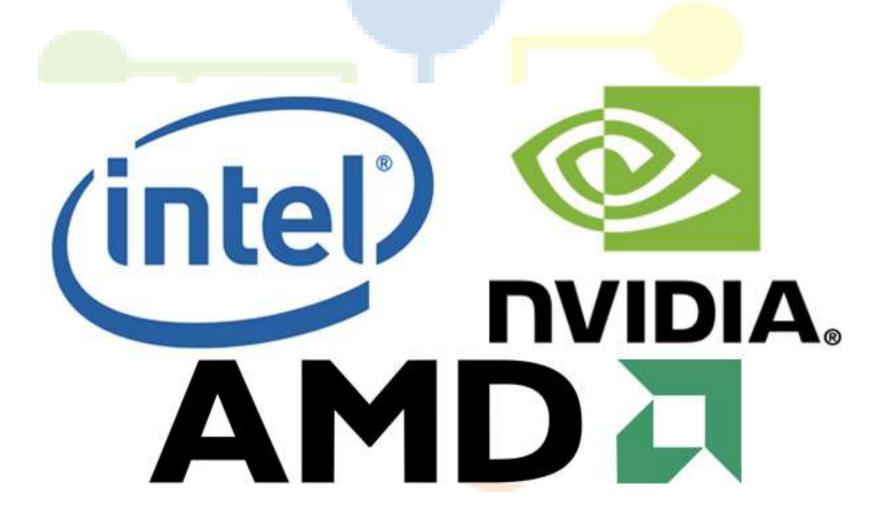
l	Block 1						
	Threads						
I.	0,0	0,1	0,2	0,3	0,4		
	1,0	1,1	1,2	1,3	1,4		
	2,0	2,1	2,2	2,3	2,4		
ľ	3,0	3,1	3,2	3,3	4,4		

Block 2							
•	Threads						
0,0	0,1	0,2	0,3	0,4			
1,0	1,1	1,2	1,3	1,4			
2,0	2,1	2,2	2,3	2,4			
3,0	3,1	3,2	3,3	4,4			





Data Science Academy raphaelbsfontenelle@gmail.com 615c1fdde32fc361b30c9ec2 História da Computação em GPU







Data Science Academy raphaelbsfontenelle@gmail.com 615c1fdde32fc361b30c9ec2 História da Computação em GPU







História da Computação em GPU

Sem GPU O processamento gráfico era feito pela própria CPU

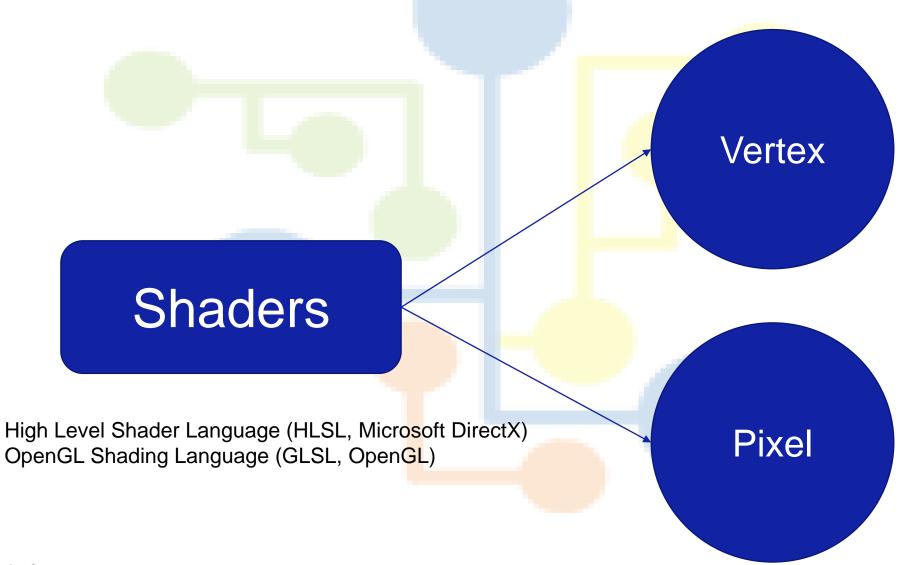
> **GPU** Dedicada Processamento gráfico separado (PCI, AGP)

> > GPU Programáveis Shaders





Data Science Academy raphaelbsfontenelle@ História da Computação em GPU







Data Science Academy raphaelbsfontenelle@gmail.com 615c1fdde32fc361b30c9ec2 História da Computação em GPU

Na segunda metade da década de 2000, os shaders passaram a ser chamados de kernels, que suportam várias linhas de código, além da introdução ao suporte a ponto flutuante de precisão dupla.





História da Computação em GPU





História da Computação em GPU



processadores se chamam Streaming Processors, ou Processadores de Fluxo (numa tradução livre), e GPUs modernas contém até milhares deles.

A GPU Titan X por exemplo possui 3584 desses Streaming Processors, ou na nomenclatura da Nvidia, CUDA cores.











General Purpose Graphical Processing Unit

Unidade de Processamento Gráfico de Propósito Geral



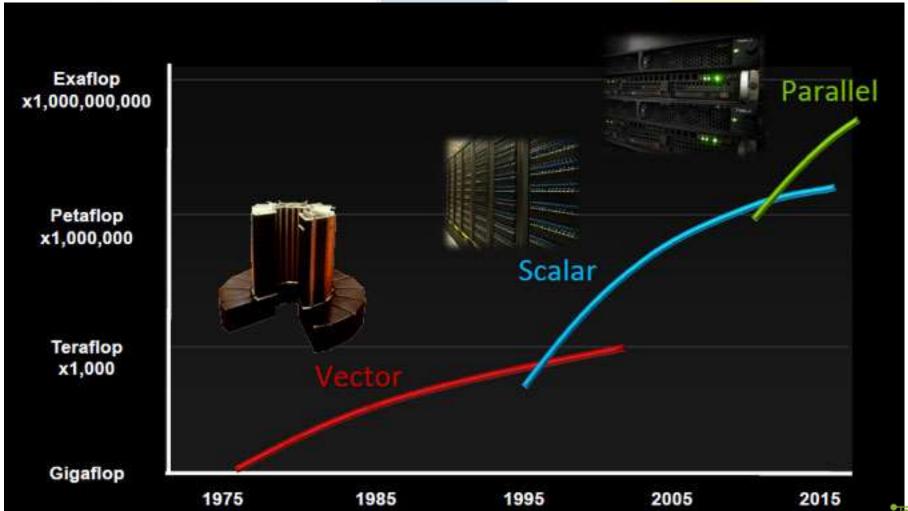




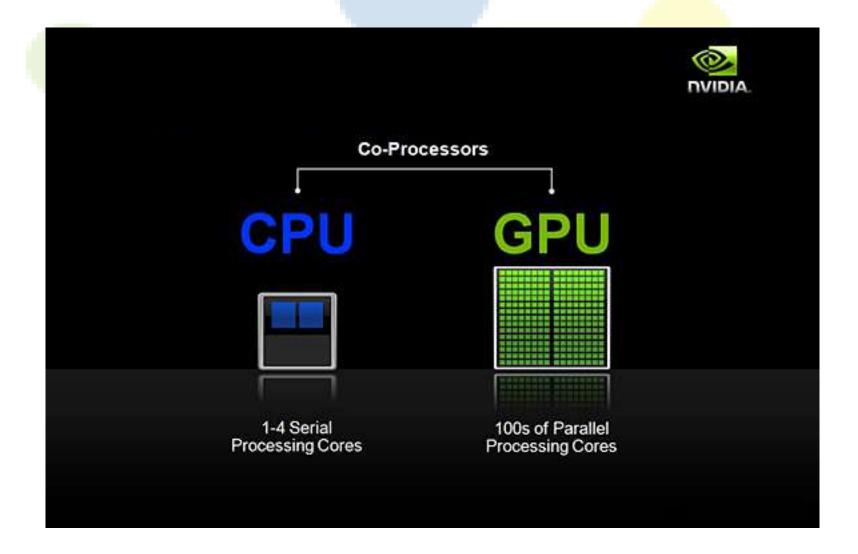
 $Data\,Science\,Academy\,raphaelbs fontenelle@gmail.com\,615c1fdde32fc361b30c9ec2$

















Arquitetura Altamente Paralelizada

Muitas Threads concorrentes (SIMT)

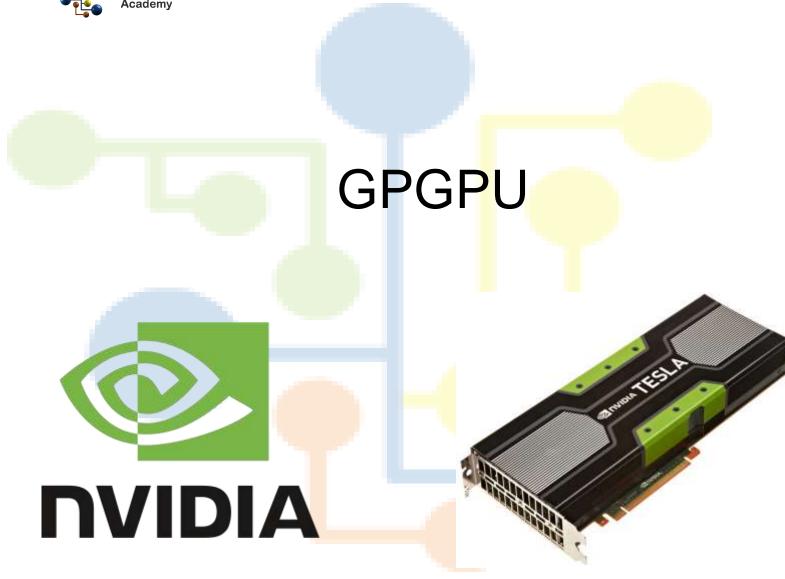
Throughput maior que as CPUs

Mais FLOPS (floating-point operations per second)





 $Data\,Science\,Academy\,raphaelbs fontenelle@gmail.com\,615c1fdde32fc361b30c9ec2$











Compute Unified Driver Architecture (CUDA)

- Desenvolvido pela Nvidia
- Extensões para linguagens de programação C e C++
- Suporte para outras linguagens, através de módulos Fortran, PyCUDA, Matlab

Open Computing Language (OpenCL)

- Suporta diversas GPUs (incluindo as Nvidia)
- A forma de realizar computação de alto nível em GPUs ATI/AMD

C++ Accelerated Massive Programming (AMP)

- Superset C++
- Parte do MSVC++ da Microsoft
- Suporta GPUs Nvidia e ATI/AMD





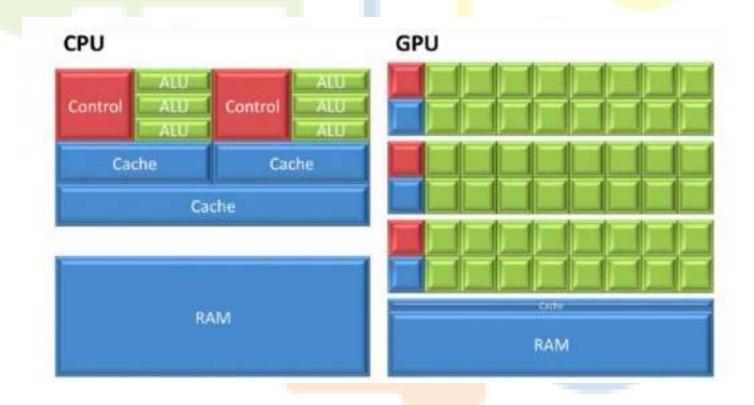
GPGPU Frameworks Data Science Academy

Alea, Aparapi, Brook

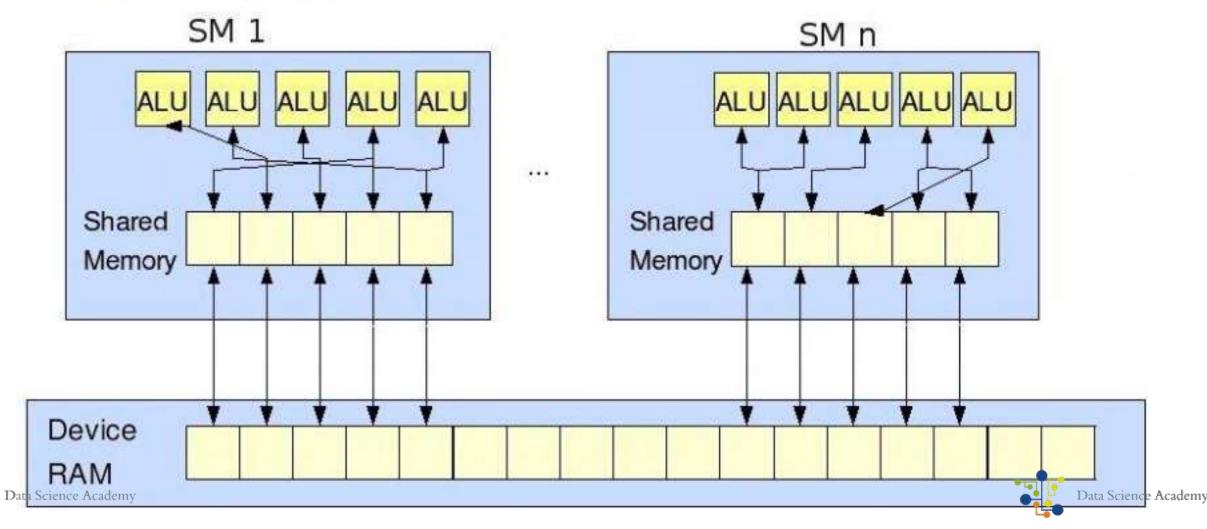








Streaming Multiprocessor





Cada SM possui vários núcleos, chamados de CUDA cores. Cada CUDA core possui pipelines completos de operações aritméticas (ALU - Arithmetic Logic Unit) e de pontos flutuantes (FPU - Floating Point Unit).

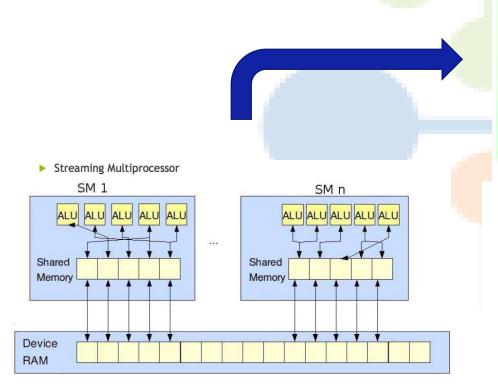
CUDA Core

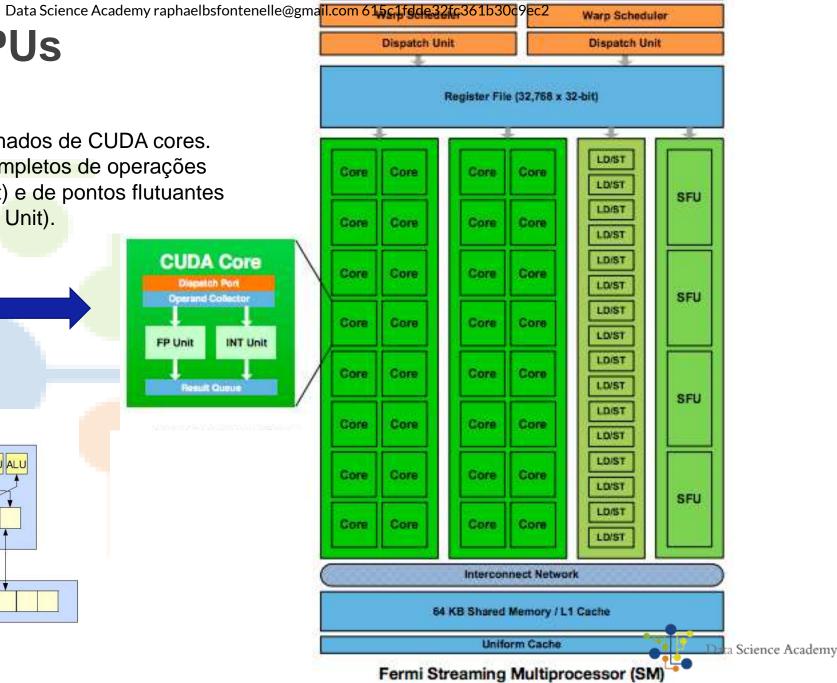
Dispatch Port

Operand Collector

Result Queue

INT Unit



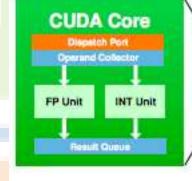


Instruction Cache



Data Science Academy raphaelbsfontenelle@gmail.com 615c1fdde32fc361b30d9ec2 Arquitetura das GPUs

Streaming Processor ou **Shader Unit**



Streaming Multiprocessor SM 1 SM n ALU ALU ALU ALU ALU ALU ALU ALU ALU Shared Shared Device RAM

Interconnect Network

64 KB Shared Memory / L1 Cache

Instruction Cache

Register File (32,768 x 32-bit)

Core

Dispatch Unit

Core

Warp Scheduler

Dispatch Unit

LD/ST

LD/ST

LDIST

LOVST

LDIST

LO/ST

LDIST

LD/ST

LOST

LD/ST

LDIST

LD/ST

LDIST

LD/ST

LD/ST

LD/ST

SFU

SFU

SFU

SFU

Uniform Cache

Data Science Academy

Fermi Streaming Multiprocessor (SM)

Data Science Academy

Arquitetura da GPU Fermi

- 16 Multiprocessadores:
- 32 processadores
- 16 unidades Load/Store
- 4 unidades funções especiais
- 64 kB Memória compartilhada
- 32768 registradores
- Cache de constantes e textura



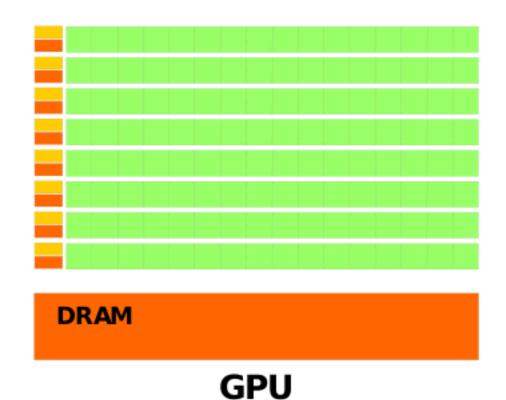




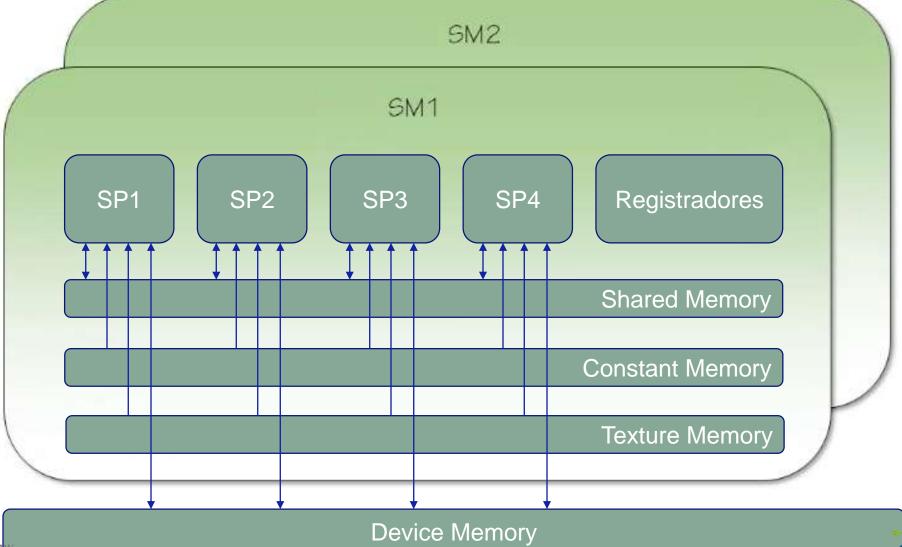


Data Science Academy raphaelbsfontenelle@gmail.com 615c1fdde32fc361b30c9ec2 Arquitetura das GPUs

Control ALU ALU ALU ALU Cache **DRAM CPU**





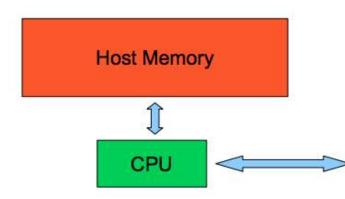


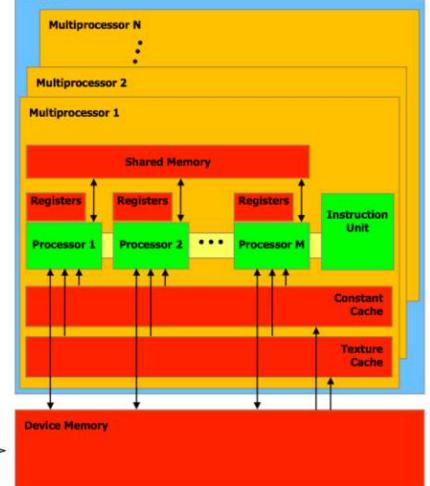


Device

Arquitetura das GPUs

Os multiprocessadores compartilham uma memória global, onde são armazenados texturas ou dados de aplicações.











Compute Capability



CUDA-Enabled GeForce Products

GeForce Desktop Products

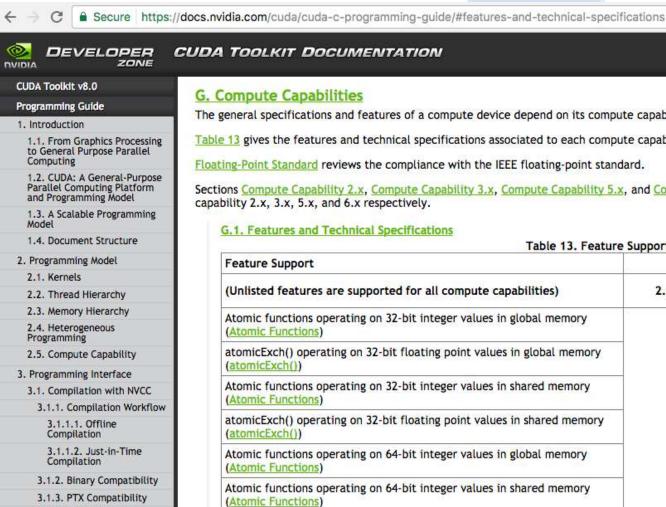
GeForce Notebook Products

GPU	Compute Capability	GPU	Compute Capability
NVIDIA TITAN Xp	6.1	GeForce GTX 1080	6.1
NVIDIA TITAN X	6.1	GeForce GTX 1070	6.1
GeForce GTX 1080 Ti	6.1	GeForce GTX 1060	6.1
GeForce GTX 1080	6.1	GeForce GTX 980	5.2
GeForce GTX 1070	6.1	GeForce GTX 980M	5.2
GeForce GTX 1060	6.1	GeForce GTX 970M	5.2
GeForce GTX 1050	6.1	GeForce GTX 965M	5.2
GeForce GTX TITAN X	5.2	GeForce GTX 960M	5.0
GeForce GTX TITAN Z	3.5	GeForce GTX 950M	5.0



Data Science Academy raphaelbsfontenelle@gmail.com 615c1fdde32fc361b30c9ec2

Compute Capability



3.1.4. Application

3.1.5. C/C++ Compatibility

Data Scien Compatibility

G. Compute Capabilities

The general specifications and features of a compute device depend on its compute capability (see Compute Capability).

Table 13 gives the features and technical specifications associated to each compute capability.

Floating-Point Standard reviews the compliance with the IEEE floating-point standard.

Sections Compute Capability 2.x, Compute Capability 3.x, Compute Capability 5.x, and Compute Capability 6.x give more details on the architecture of devices of compute capability 2.x, 3.x, 5.x, and 6.x respectively.

G.1. Features and Technical Specifications

Table 13.	Feature	Support	per Compute	Capability

Feature Support	Compute Capability					
(Unlisted features are supported for all compute capabilities)	2.x	3.0	3.2	3.5, 3.7, 5.0, 5.2	5.3	6.x
Atomic functions operating on 32-bit integer values in global memory (Atomic Functions)						
atomicExch() operating on 32-bit floating point values in global memory (atomicExch())						
Atomic functions operating on 32-bit integer values in shared memory (Atomic Functions)						
atomicExch() operating on 32-bit floating point values in shared memory (atomicExch())				Yes		
Atomic functions operating on 64-bit integer values in global memory (Atomic Functions)						
Atomic functions operating on 64-bit integer values in shared memory (Atomic Functions)						
Atomic addition operating on 32-bit floating point values in global and shared memory (atomicAdd())						Data Science Acade n

Compute Capability

Compute Capability é um número que indica o que a GPU pode fazer:

- Range atual: 1.0, 1.1, 1.2, 1.3, 2.0, 2.1, 3.0, 3.5, 3.7, 5.0, 5.3, 6.0, 6.1, 6.2, 7.0
- Titan X e GTX 1080 TI possuem Compute Capability igual a 6.1
- Tesla Volta (nova arquitetura anunciada em Maio/2017) possui Compute Capability igual a 7.0

Compute Capability afeta o suporte ao hardware a APIs:

- Número de CUDA cores por SM
- Máximo de registradores 32 bits por SM
- Máximo de instruções por kernel
- Suporte a operações de precisão dupla







Como Escolher uma GPU





Como Escolher uma GPU

- Especificações de Performance (FLOPS)
- Precisão Single x Double
- > Total de Memória da GPU
- Compute Capability
- > Arquitetura
- ➤ GPUs Simples / GPUs Workstation / GPUs Servidores (Tesla)
- Certifique-se que sua Motherboard/PSU suportam a GPU
- ➤ Mais de uma GPU?





Como Escolher uma GPU





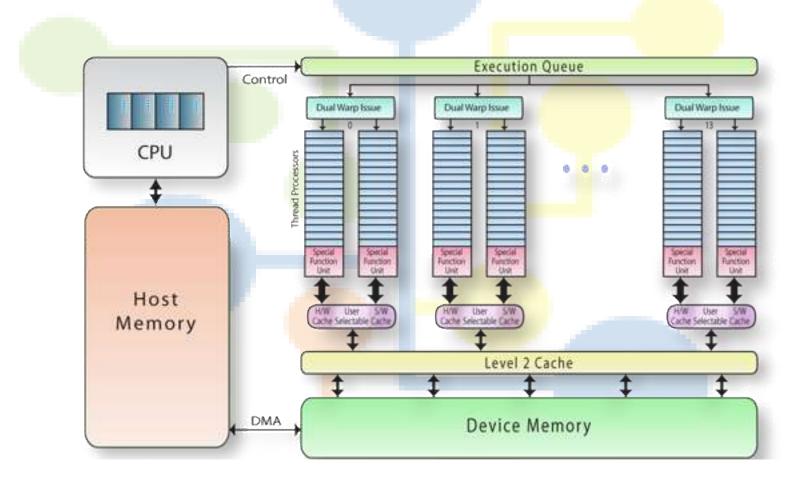


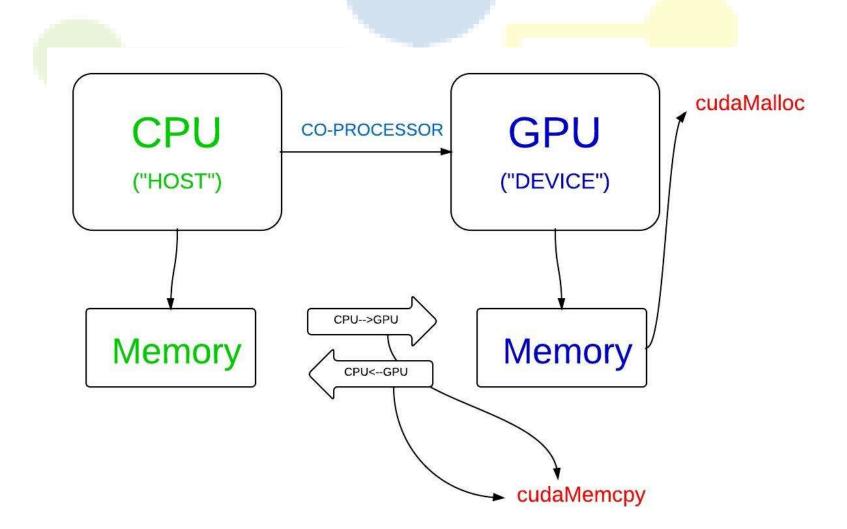
MacBook Pro (late 2016) Radeon Pro 455





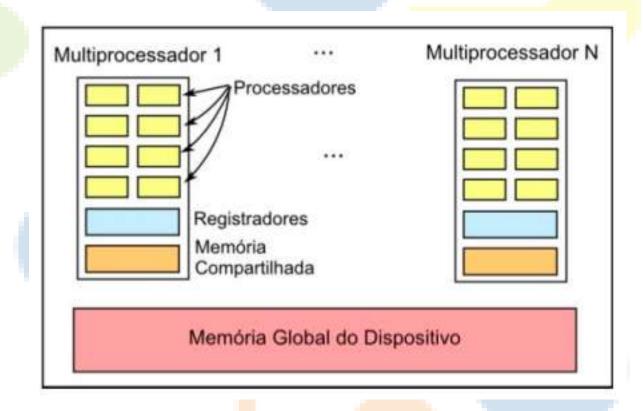












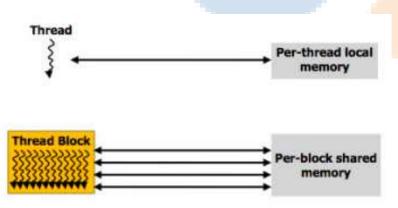
Em uma GPU, 7 operações de ponto flutuante podem ser executadas por um núcleo de processamento ao mesmo tempo que 1 byte demora para ser transferido da memoria externa para a GPU

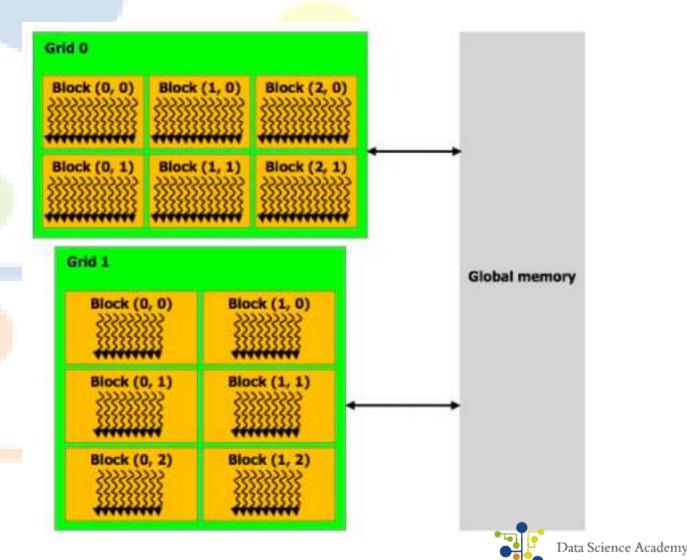




Cada execução do kernel é composta por:

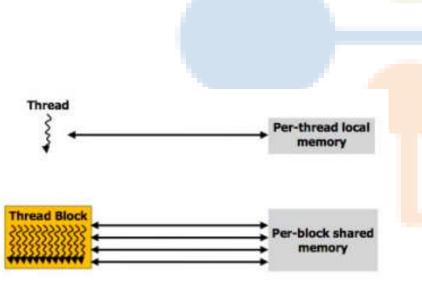
Grids → Blocks→ Threads

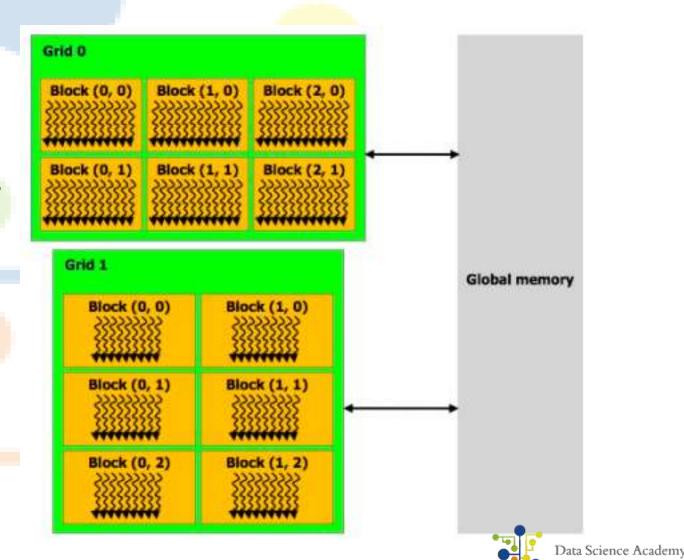






- Registradores por thread
- Memória compartilhada por bloco
- Memória global acessível a todas as threads



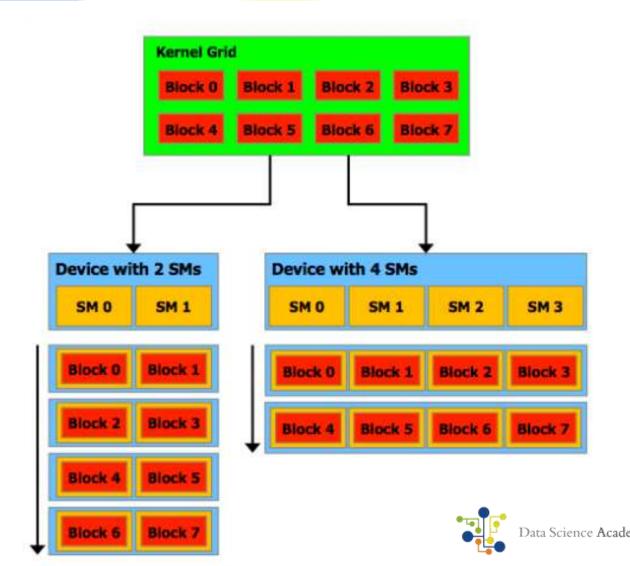




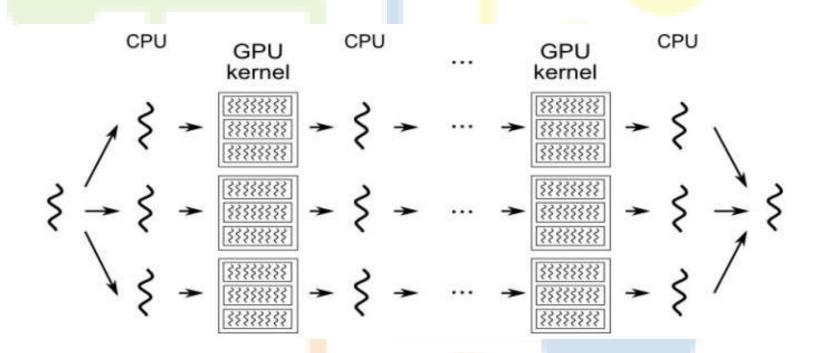
E como ocorre a execução de aplicações?

Cada bloco é alocado a um multiprocessador (Streaming Multiprocessor) da GPU, que pode executar 1 ou mais blocos simultaneamente.

Cada multiprocessador executa 16 threads no modelo SIMT: Single Intruction, Multiple Thread







A execução do programa controlado pela CPU pode lançar kernels, que são trechos de código executados em paralelo por múltiplas threads na GPU.







Deadlock e Starvation Data Science Academy Data Science Academy

Deadlock

A espera B e B espera A e ambos esperam um ao outro

Starvation

A espera B mas nunca recebe uma resposta





Deadlock e Starvation Data Science Academy Data Science Academy

Deadlock causa Starvation, mas Starvation não causa Deadlock

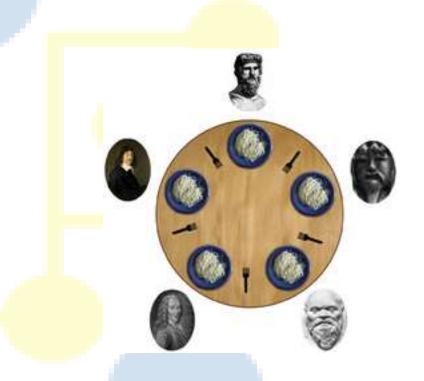




Deadlock e Starvation Data Science Academy Data Science Academy



Deadlock



Dinning Philosophers Problem Starvation





Obrigado



